

# Трекинг экспериментов и мониторинг ML-систем

TensorBoard · MLflow · W&B

A/B-тесты · Prometheus · Grafana

## Сегодня на занятии

### Обучение

Параметры · метрики · модель  
TensorBoard · MLflow · W&B



### A/B-тест

Эффект · доверительный интервал  
Статистическая значимость



### Мониторинг

Ошибки · задержка · нагрузка  
Prometheus · Grafana

# TensorBoard




График accuracy

X — шаг

Y — доля верных  
ОТВЕТОВ

```
writer.add_scalar("accuracy/train", accuracy, step)
```

## Запись запуска в MLflow

Run — запуск; параметры → метрики → артефакты

```
import mlflow, joblib
from sklearn.linear_model import LogisticRegression

with mlflow.start_run():
    model = LogisticRegression(C=1, max_iter=300)
    model.fit(X_train, y_train)
    accuracy = model.score(X_val, y_val)
    joblib.dump(model, "model.pkl")
    mlflow.log_param("C", 1)
    mlflow.log_metric("accuracy", accuracy)
    mlflow.log_artifact("model.pkl")
```

# Параметры, метрики, артефакты

MLFLOW QUICKSTART > RUNS >

thundering-fly-695

Overview

Model metrics

System metrics

Traces

Artifacts

Description

No description

Metrics (7)

Q Search metrics

| Metric                   | Value               | Models                |
|--------------------------|---------------------|-----------------------|
| training_score           | 0.975               | <a href="#">model</a> |
| training_roc_auc         | 0.9981238273921201  | <a href="#">model</a> |
| training_accuracy_score  | 0.975               | <a href="#">model</a> |
| training_precision_score | 0.9767857142857144  | <a href="#">model</a> |
| training_log_loss        | 0.13562857756813249 | <a href="#">model</a> |
| training_f1_score        | 0.9749882794186592  | <a href="#">model</a> |
| training_recall_score    | 0.975               | <a href="#">model</a> |

Parameters (15)

Q Search parameters


| Parameter    | Value  |
|--------------|--------|
| tol          | 0.0001 |
| penalty      | l2     |
| class_weight | None   |
| random_state | 8888   |

Parameters —  
настройки


Metrics —  
результаты

Artifacts — файлы

# Сравнение запусков и хранение



# W&B



Проект — общие запуски

Графики — сравнение


Артефакты — файлы

## Offline-оценка и A/B-тест

### Offline



### A/B-тест




Один пользователь → один вариант

## План A/B-теста

- Конверсия; защита: ошибки, задержка
- Полезный порог: +0.5 п.п.
- $\alpha = 0.05$ : риск ложноположительного вывода
- Мощность 80%: вероятность обнаружить заданный эффект

# Эффект и доверительный интервал

10% → 11%: +1 п.п. = +10% относительно А



Стандартная ошибка

$$SE = \sqrt{\frac{p_A(1 - p_A)}{n_A} + \frac{p_B(1 - p_B)}{n_B}}$$

95% интервал

$$(p_B - p_A) \pm 1.96 \cdot SE$$

$p$  — доля покупателей

$n$  — пользователей в группе

Независимые наблюдения

**Больше пользователей → меньше SE → уже интервал**

При прочих равных:  $n \times 4 \rightarrow SE \div 2 \rightarrow \text{ширина} \div 2$

## Проверка различия конверсий

$H_0$ : вероятность покупки одинакова

```
from statsmodels.stats.proportion import proportions_ztest


# B: 1100 покупателей; A: 1000. По 10 000 пользователей.
# Под  $H_0$ :  $Z \sim N(0, 1)$ ;  $z_{набл} \approx 2.307$ .
z, p = proportions_ztest([1100, 1000], [10000, 10000])
print(f"p = {p:.3f}")
```

**$p = 0.021 < \alpha = 0.05$**


$p\text{-value} = P(|Z| \geq |z_{набл}| \mid H_0)$

$p\text{-value}$ : вероятность не менее экстремального результата при  $H_0$

## Значимость и полезный эффект



## Мониторинг качества модели



### Положительный класс

Метка 1:  
рекомендованный товар  
куплен в течение 24 ч  
после показа


# Логи и метрики

## Лог — один запрос

```
12:07:03 ERROR request_id=42  
TimeoutError: model_inference  
model_version=v2  
timeout=1s
```

Модель не ответила за 1 с

## Метрика — число таймаутов



Время всплеска → события в логах

# Метрики сервиса и метки

/metrics — HTTP-адрес с измерениями сервиса

`requests_total{variant="A",status="ok"} 1250`

Имя метрики      Метки      Значение счётчика

**2 варианта × 2 статуса = 4 ряда**

|       | A    | B    |
|-------|------|------|
| ok    | 1250 | 1300 |
| error | 12   | 15   |

**user\_id и request\_id → логи**


# Как Prometheus собирает метрики



# Counter, Gauge, Histogram

## Counter


Накопительный счётчик



Сброс при перезапуске


## Gauge

Текущее значение



## Histogram

Распределение задержек




`B /metrics (classic):`

$\leq 0.1$  с: 6

$\leq 0.3$  с:  $6 + 12 = 18$

# Запросы в Grafana

Панель — график результата запроса



Источник:  
Prometheus

PromQL — язык  
запросов


rate — запросы / с

[5m] — последние 5  
минут

```
rate(requests_total[5m])
```

# Дашборд Grafana

Дашборд — экран панелей с общим диапазоном времени



В ML-сервисе: нагрузка · ошибки · задержка

[Grafana](#)

# Оповещения и Pending

## 4. Set evaluation behavior

Define how the alert rule is evaluated. [? Need help?](#)

Select a folder before setting evaluation group and interval

Select an evaluation group... ▾

 or 

+ New evaluation group

**Pending period**  
Period during which the threshold condition must be met to trigger an alert.  
Selecting "None" triggers the alert immediately once the condition is met.

1m

None

1m

2m

3m

4m

5m

Keep firing for

Alert — оповещение

Порог: ошибки >5%

Pending — ждём 60 с

Нарушение сохраняется  
→ сигнал

# Итоги

- Трекинг — параметры, метрики и файлы запуска.
- A/B-тест — эффект, неопределённость и полезный порог.
- Мониторинг — ошибки, задержка и качество модели.