

Трекинг экспериментов и мониторинг ML-систем

TensorBoard · MLflow · W&B

A/B-тесты · Prometheus · Grafana

Сегодня на занятии



TensorBoard




График accuracy

X — шаг

Y — доля верных
ОТВЕТОВ

```
writer.add_scalar("accuracy/train", accuracy, step)
```

Запись запуска в MLflow

Run — запуск; параметры → метрики → артефакты

```
import mlflow, joblib
from sklearn.linear_model import LogisticRegression

with mlflow.start_run():
    model = LogisticRegression(C=1, max_iter=300)
    model.fit(X_train, y_train)
    accuracy = model.score(X_val, y_val)
    joblib.dump(model, "model.pkl")
    mlflow.log_param("C", 1)
    mlflow.log_metric("accuracy", accuracy)
    mlflow.log_artifact("model.pkl")
```

Параметры, метрики, артефакты

MLFLOW QUICKSTART > RUNS >

thundering-fly-695

Overview

Model metrics

System metrics

Traces

Artifacts

Description

No description

Metrics (7)

Q Search metrics

Metric	Value	Models
training_score	0.975	model
training_roc_auc	0.9981238273921201	model
training_accuracy_score	0.975	model
training_precision_score	0.9767857142857144	model
training_log_loss	0.13562857756813249	model
training_f1_score	0.9749882794186592	model
training_recall_score	0.975	model

Parameters (15)

Q Search parameters


Parameter	Value
tol	0.0001
penalty	l2
class_weight	None
random_state	8888

Parameters —
настройки


Metrics —
результаты

Artifacts — файлы

Сравнение запусков и хранение



W&B



Проект — общие запуски

Графики — сравнение


Артефакты — файлы

Offline-оценка и A/B-тест

Offline



A/B-тест



Один пользователь → один вариант

План A/B-теста

- Полезный порог: +0.5 п.п.
- $\alpha = 0.05$: риск ложноположительного вывода
- Мощность 80%: вероятность обнаружить заданный эффект

Проверка различия конверсий

H_0 : вероятность покупки одинакова

```
from statsmodels.stats.proportion import proportions_ztest

# B: 1100 покупателей; A: 1000. По 10 000 пользователей.
# Под  $H_0$ :  $Z \sim N(0, 1)$ ;  $знабл \approx 2.307$ .
z, p = proportions_ztest([1100, 1000], [10000, 10000])
print(f"p = {p:.3f}")
```


$p = 0.021 < \alpha = 0.05$

$p\text{-value} = P(|Z| \geq |знабл| \mid H_0)$

$p\text{-value}$: вероятность не менее экстремального результата при H_0

Эффект и доверительный интервал

10% → 11%: +1 п.п. = +10% относительно А



Стандартная ошибка

$$SE = \sqrt{\frac{p_A(1 - p_A)}{n_A} + \frac{p_B(1 - p_B)}{n_B}}$$

95% интервал

$$(p_B - p_A) \pm 1.96 \cdot SE$$

p — доля покупателей


n — пользователей в группе

Независимые наблюдения


Больше пользователей → меньше SE → уже интервал

При прочих равных: $n \times 4 \rightarrow SE \div 2 \rightarrow \text{ширина} \div 2$

Значимость и полезный эффект



Мониторинг качества модели



Положительный класс

Метка 1:
рекомендованный товар
куплен в течение 24 ч
после показа


Логи и метрики

Лог — один запрос

```
12:07:03 ERROR request_id=42  
TimeoutError: model_inference  
model_version=v2  
timeout=1s
```

Модель не ответила за 1 с

Метрика — число таймаутов



Время всплеска → события в логах

Метрики сервиса и метки

/metrics — HTTP-адрес с измерениями сервиса

requests_total{variant="A", status="ok"} 1250

Имя метрики Метки Значение счётчика

2 варианта × 2 статуса = 4 ряда

	A	B
ok	1250	1300
error	12	15

user_id и request_id → логи


Как Prometheus собирает метрики



Counter, Gauge, Histogram

Counter


Накопительный счётчик



Сброс при перезапуске


Gauge

Текущее значение



Histogram

Распределение задержек




`B /metrics (classic):`

≤ 0.1 с: 6

≤ 0.3 с: $6 + 12 = 18$

Запросы в Grafana

Панель — график результата запроса



Источник:
Prometheus

PromQL — язык
запросов


rate — запросы / с

[5m] — последние 5
минут

```
rate(requests_total[5m])
```

Дашборд Grafana

Дашборд — экран панелей с общим диапазоном времени



В ML-сервисе: нагрузка · ошибки · задержка

[Grafana](#)

Оповещения и Pending

4. Set evaluation behavior

Define how the alert rule is evaluated. [? Need help?](#)

Select a folder before setting evaluation group and interval

Select an evaluation group... ▾

 or

+ New evaluation group

Pending period
Period during which the threshold condition must be met to trigger an alert.
Selecting "None" triggers the alert immediately once the condition is met.

1m

None

1m

2m

3m

4m

5m

Keep firing for

Alert — оповещение

Порог: ошибки >5%

Pending — ждём 60 с

Нарушение сохраняется
→ сигнал

Итоги

- Трекинг — параметры, метрики и файлы запуска.
- A/B-тест — эффект, неопределённость и полезный порог.
- Мониторинг — ошибки, задержка и качество модели.