NVIDIA GPU и CUDA

Устройство, выполнение и диагностика ML-вычислений



NVIDIA

Сегодня на занятии

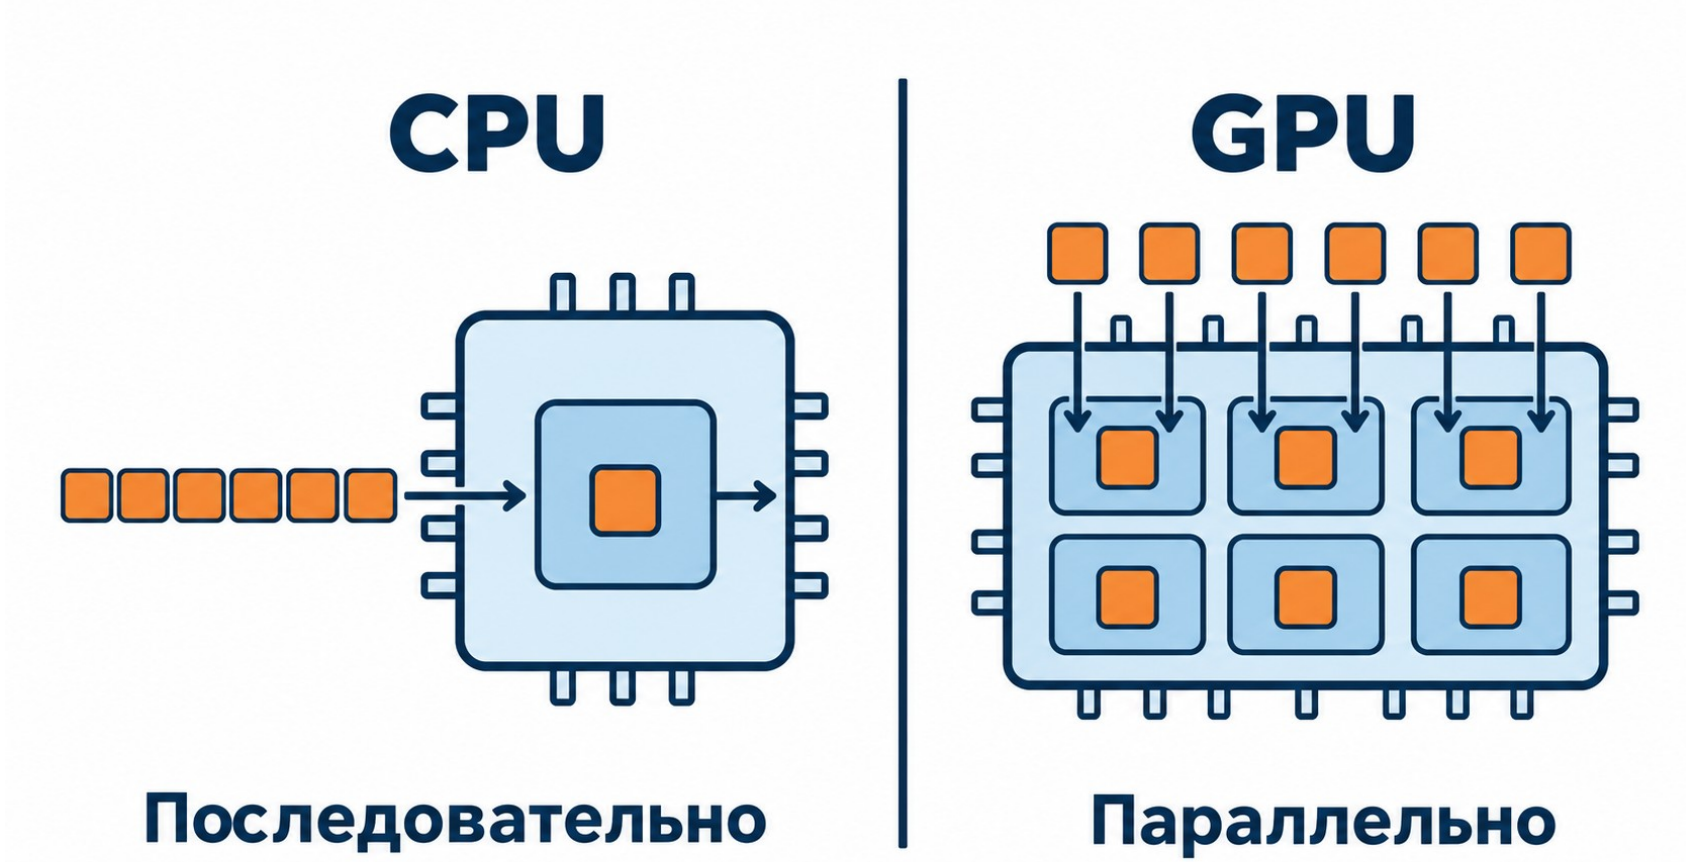
- Устройство GPU и выполнение CUDA
- Память и передача данных
- Точность и матричные операции
- Измерение и мониторинг

Путь ML-запроса



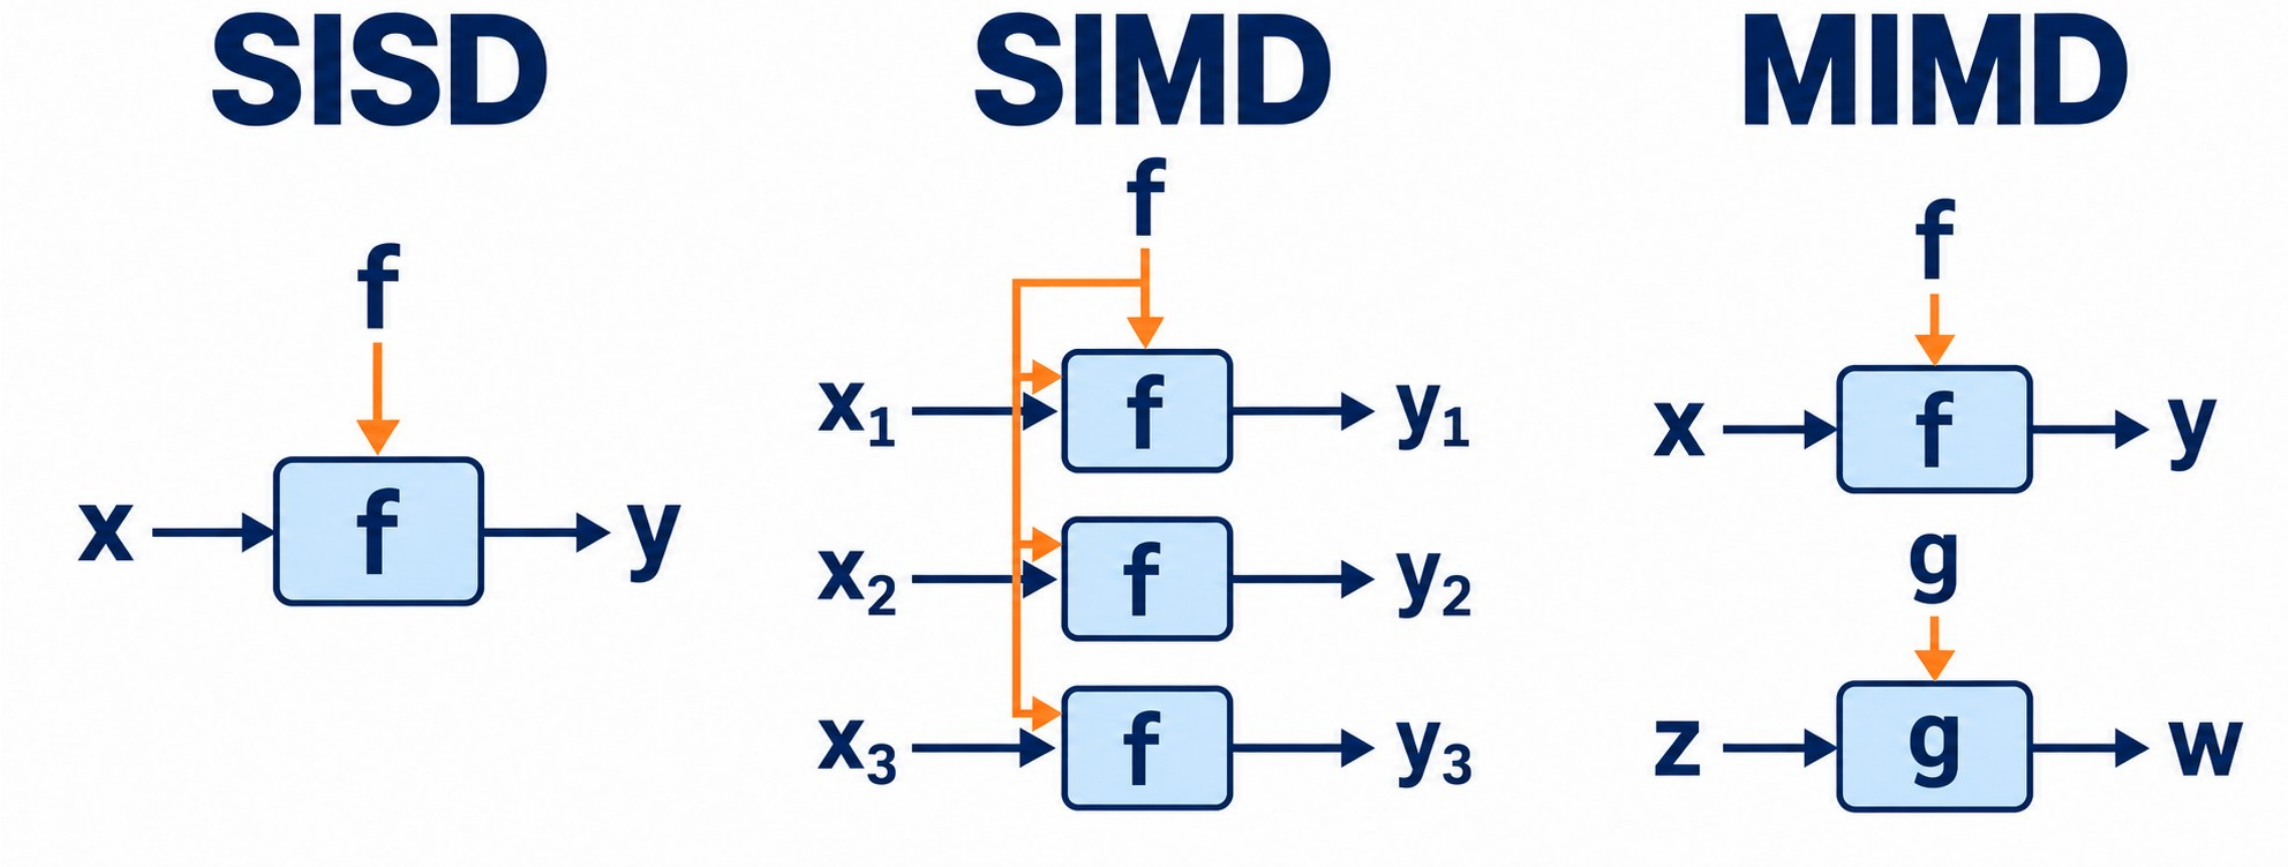
NVIDIA

CPU и GPU

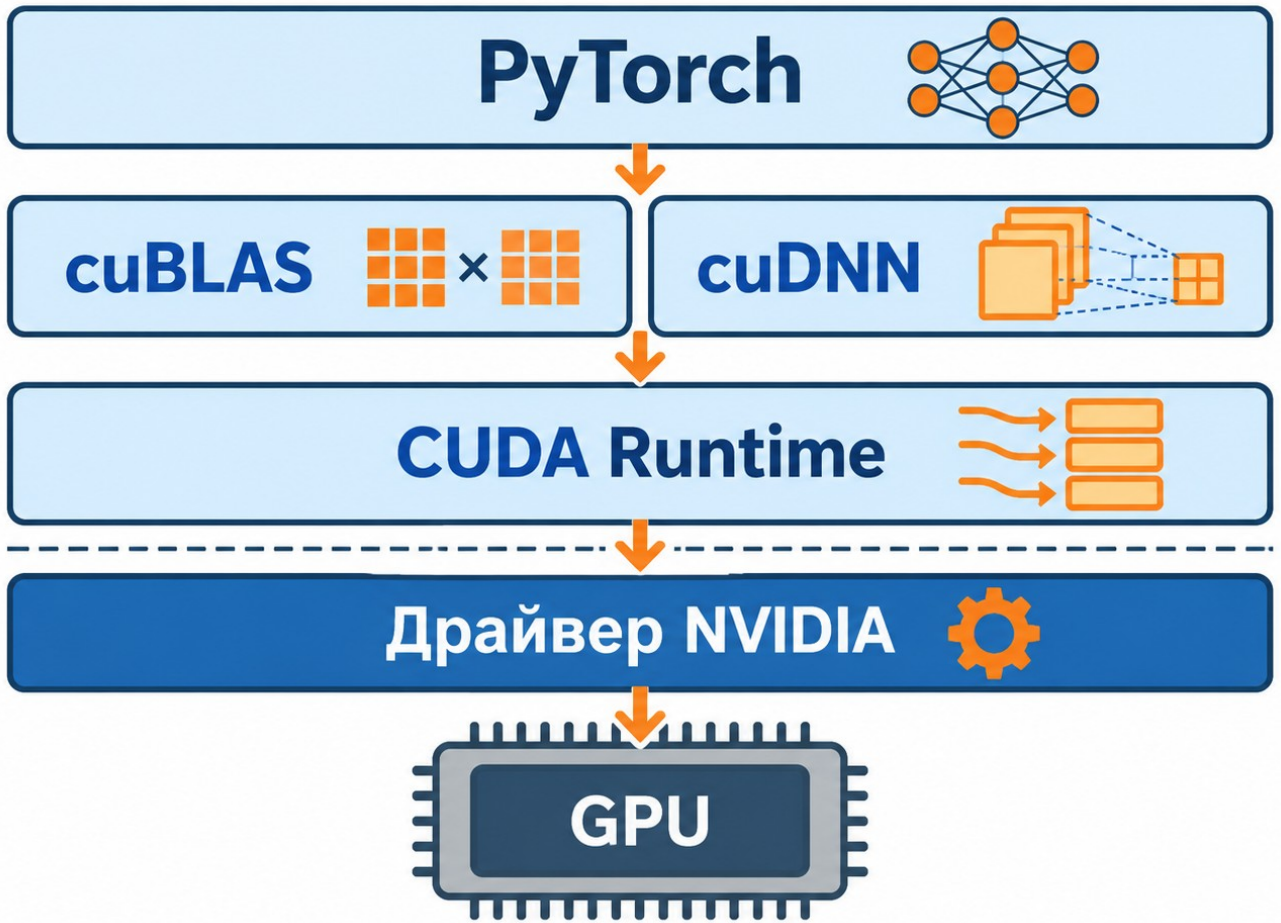


NVIDIA

SISD, SIMD и MIMD

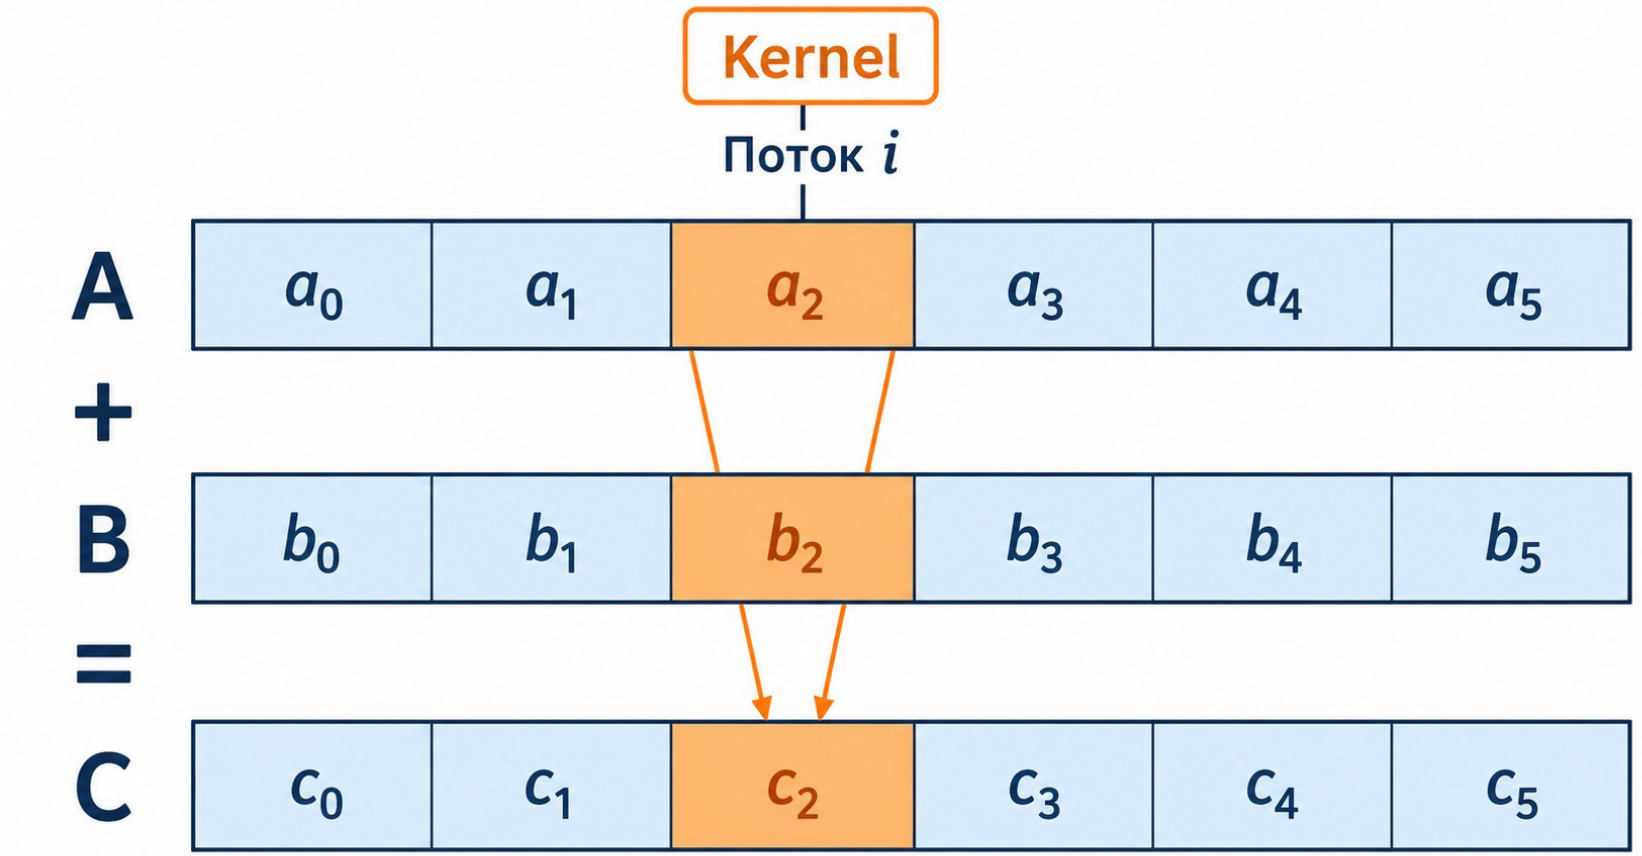


Что такое CUDA

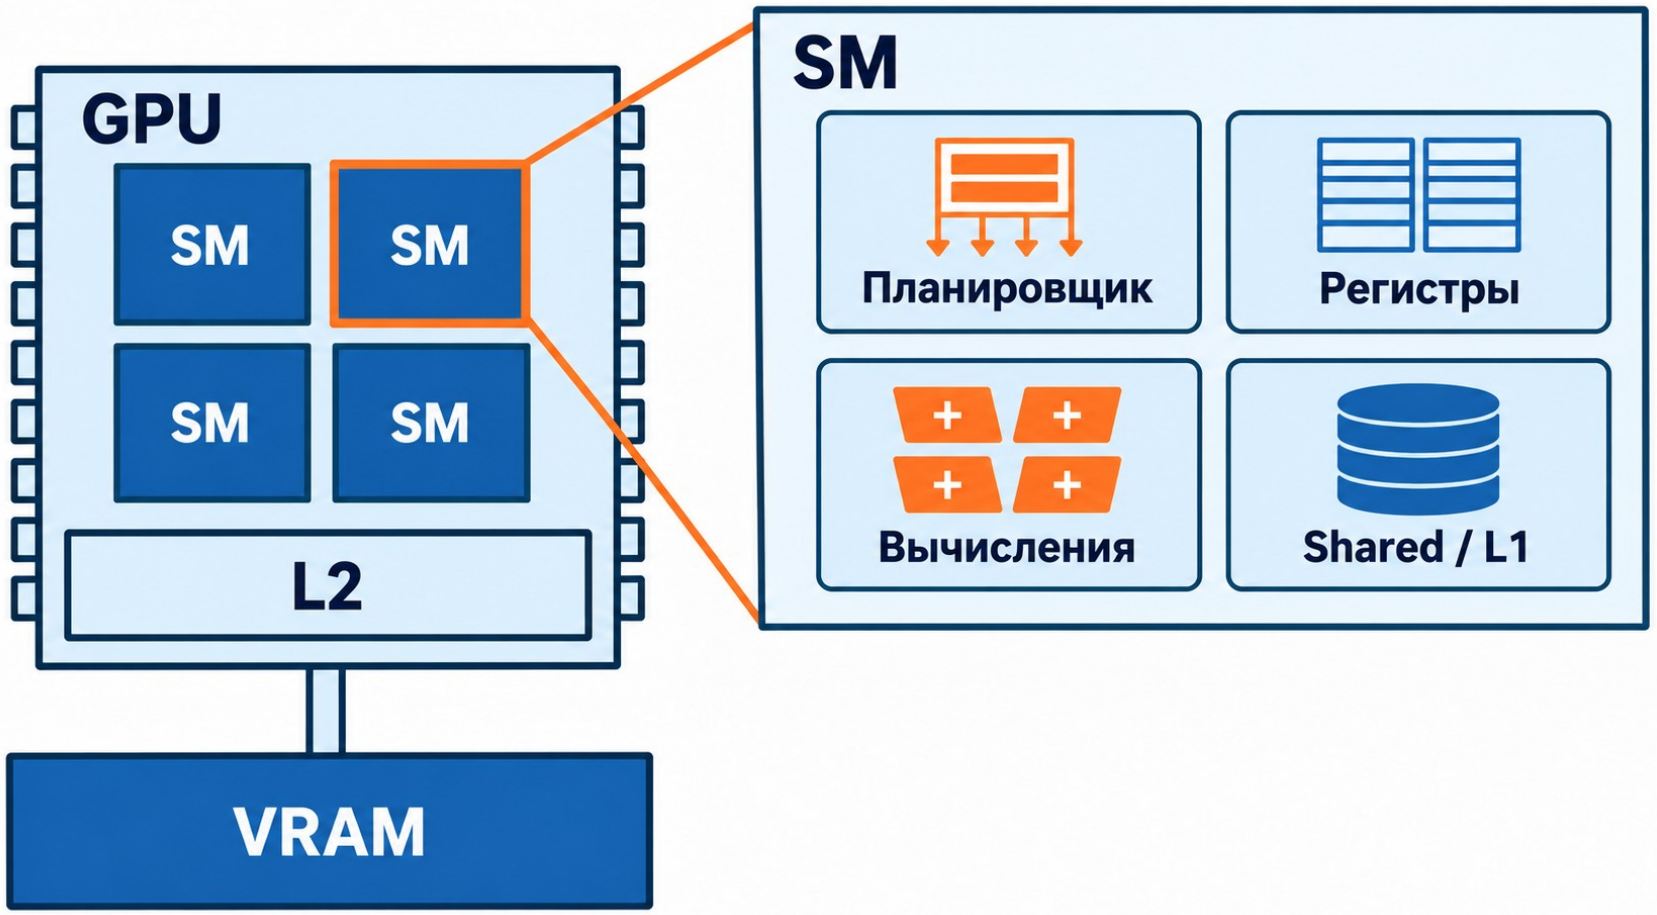


NVIDIA

Kernel: одна операция, много потоков

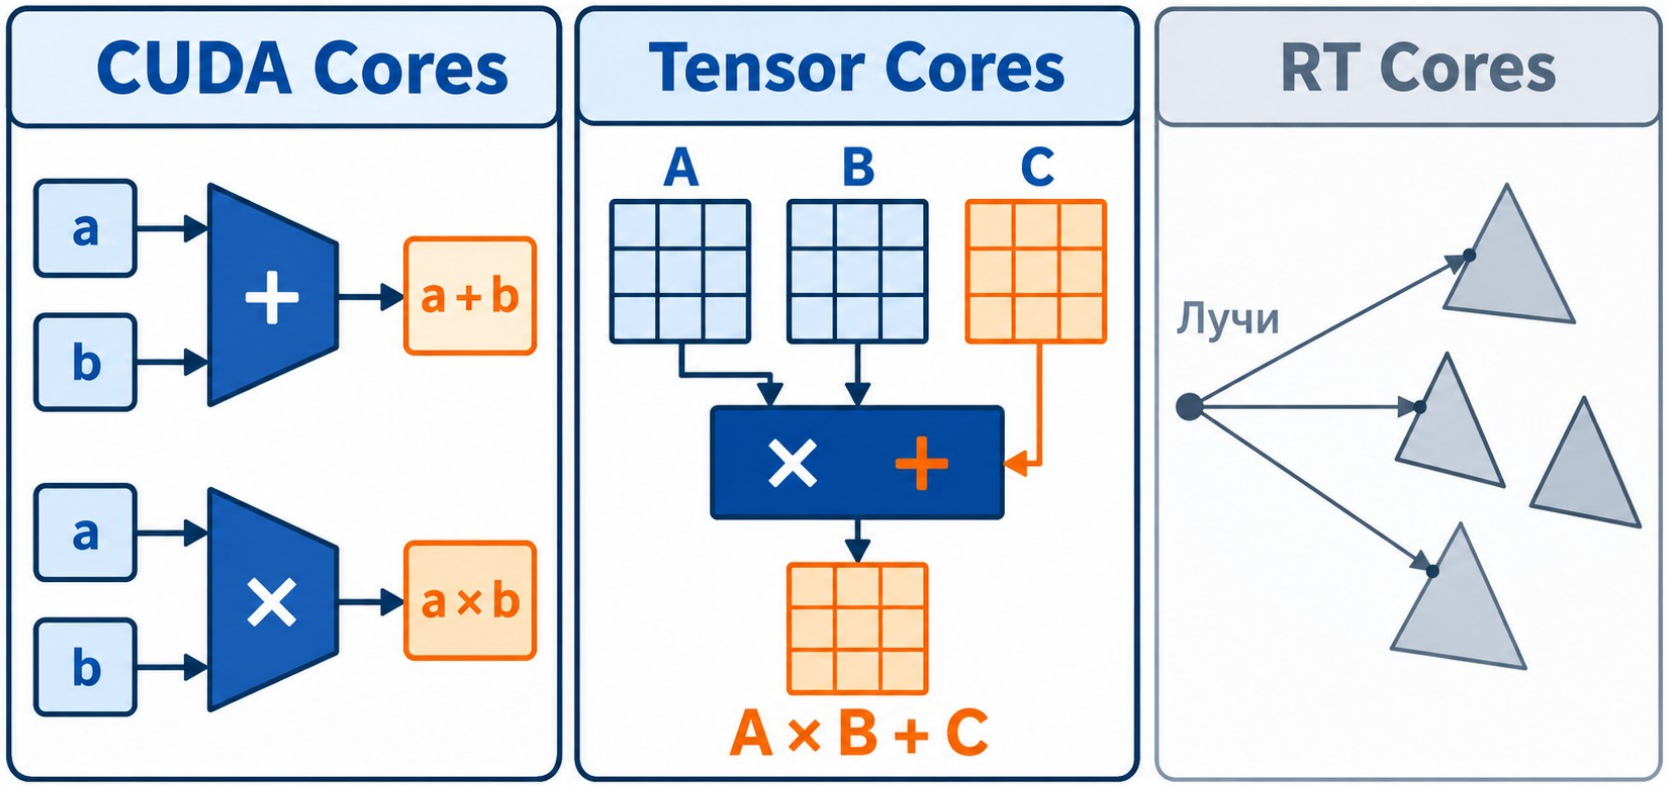


GPU и Streaming Multiprocessor



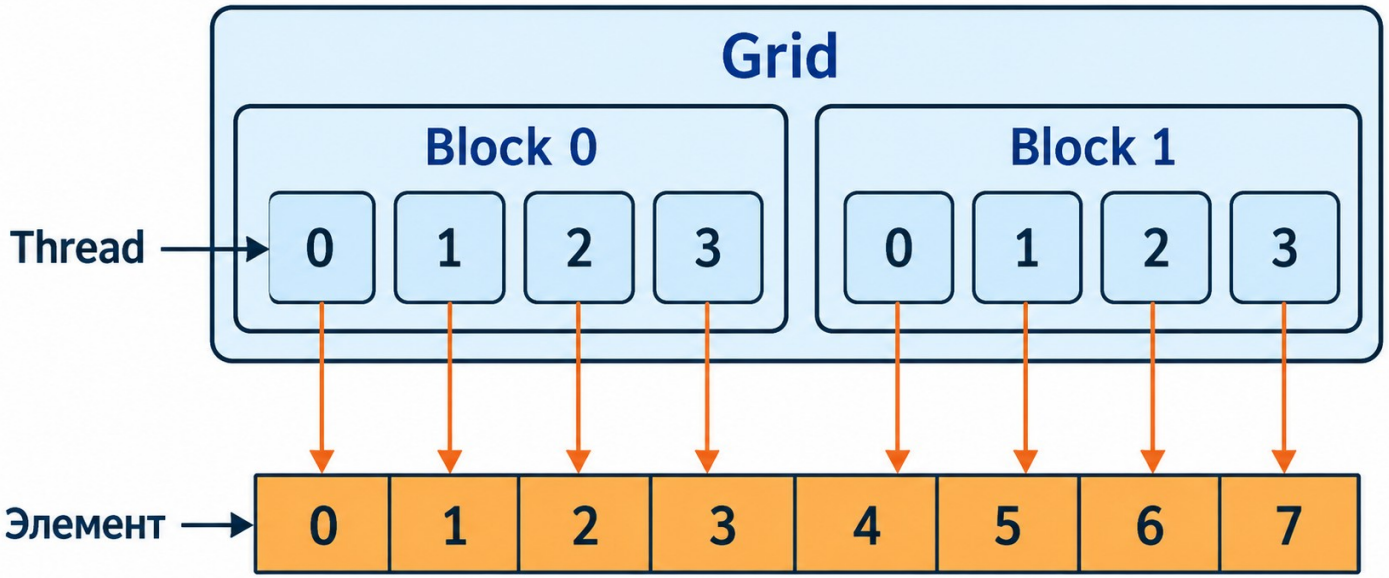
NVIDIA

CUDA, Tensor и RT Cores



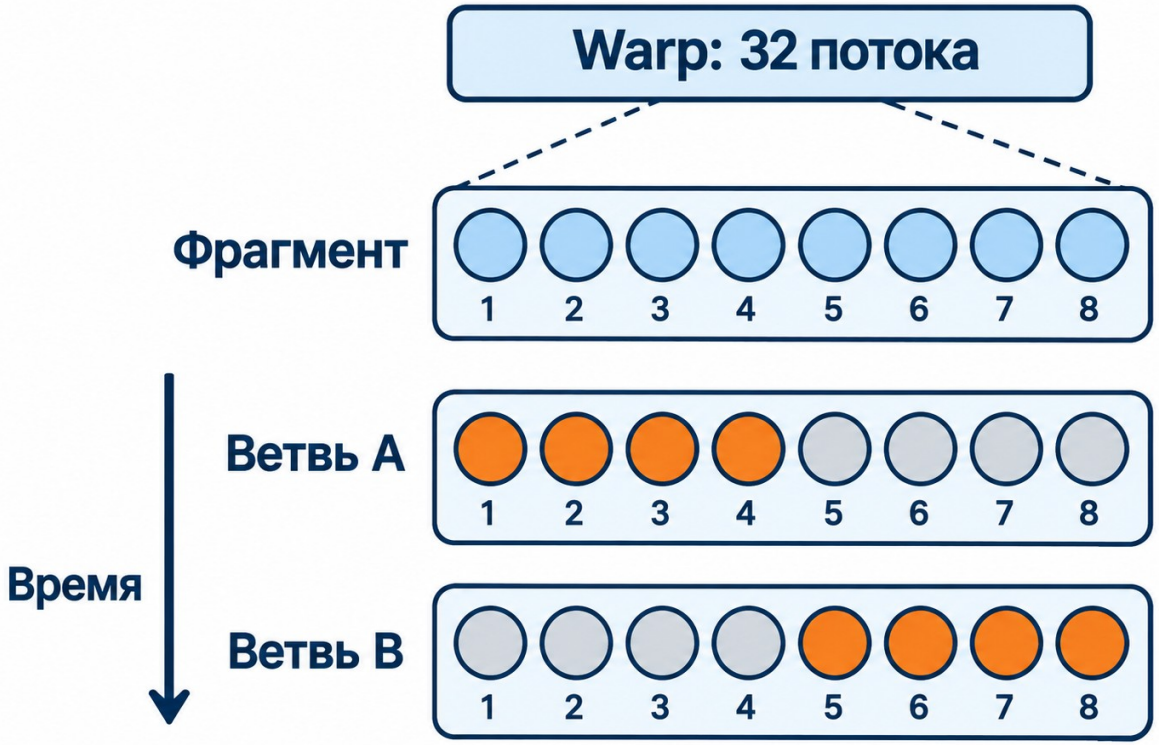
NVIDIA

Thread, block и grid



- Thread: выполнение kernel со своим индексом
- Block: группа threads на одном SM
- Grid: все blocks одного запуска

Warp и ветвления



- Warp: 32 threads одного block
- SIMT: общая инструкция активным threads warp
- Divergence: разные ветви внутри warp

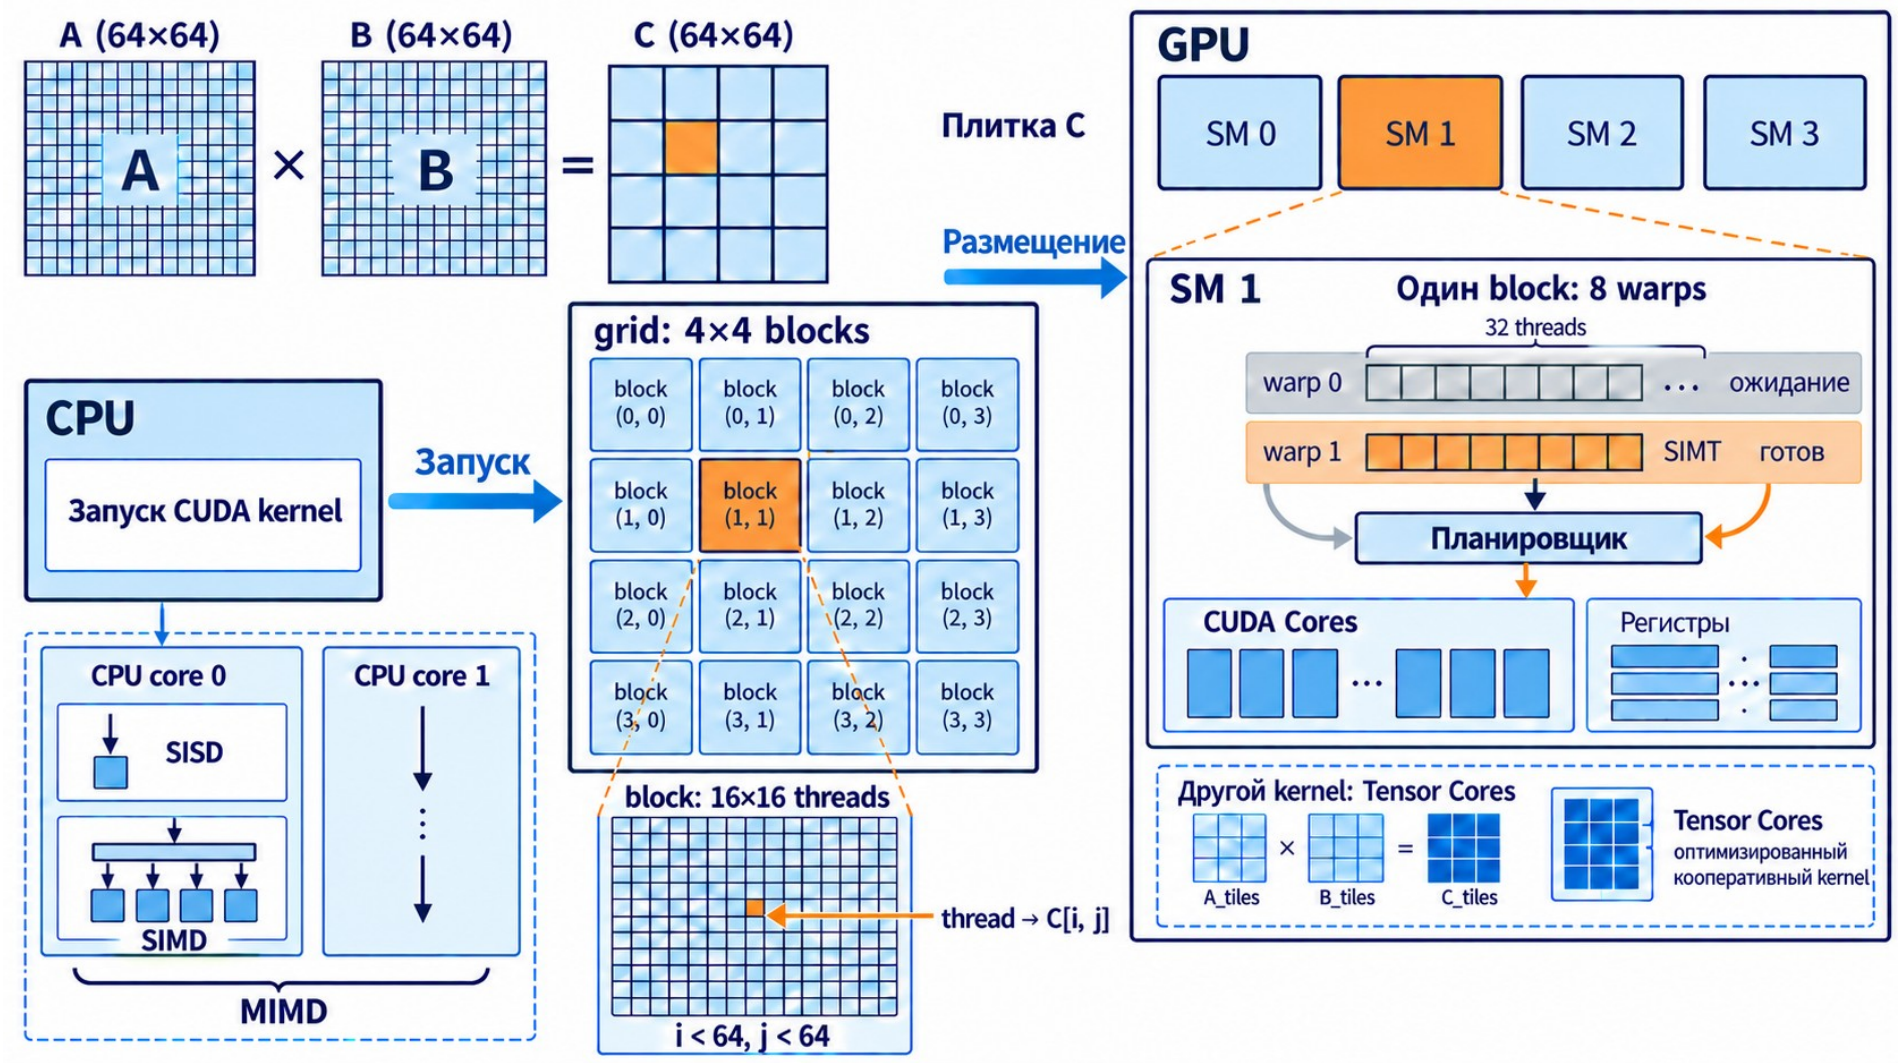
NVIDIA

Планирование и ожидание данных



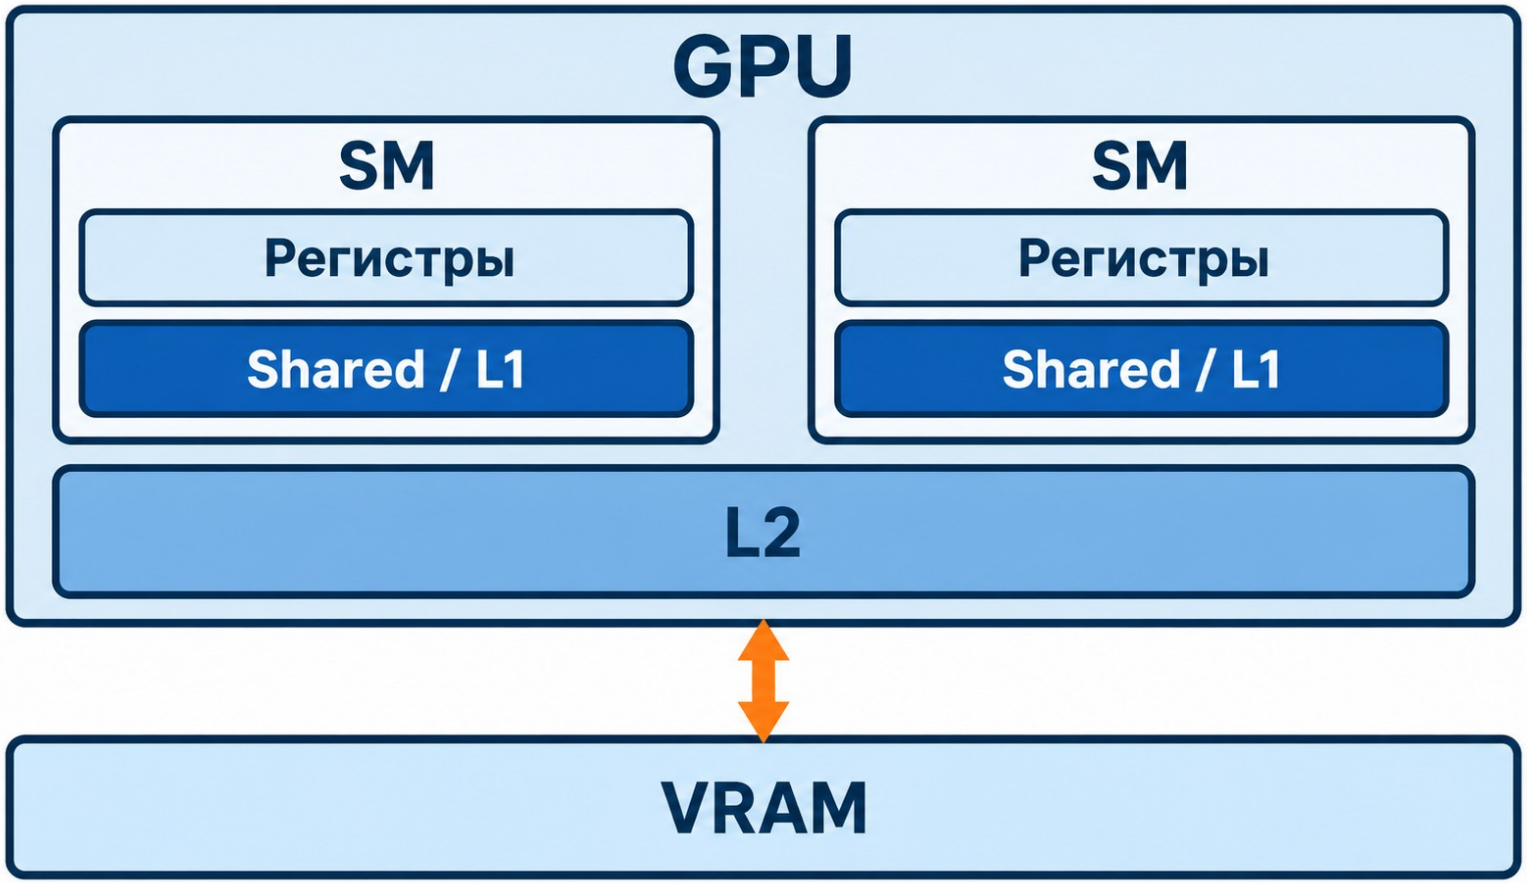
- Планировщик выбирает готовый warp
- Ожидание перекрывается работой других warps
- Нет готовых warps — вычислители простаивают
- Occupancy: резидентные warps / максимум SM

Матричное умножение на GPU



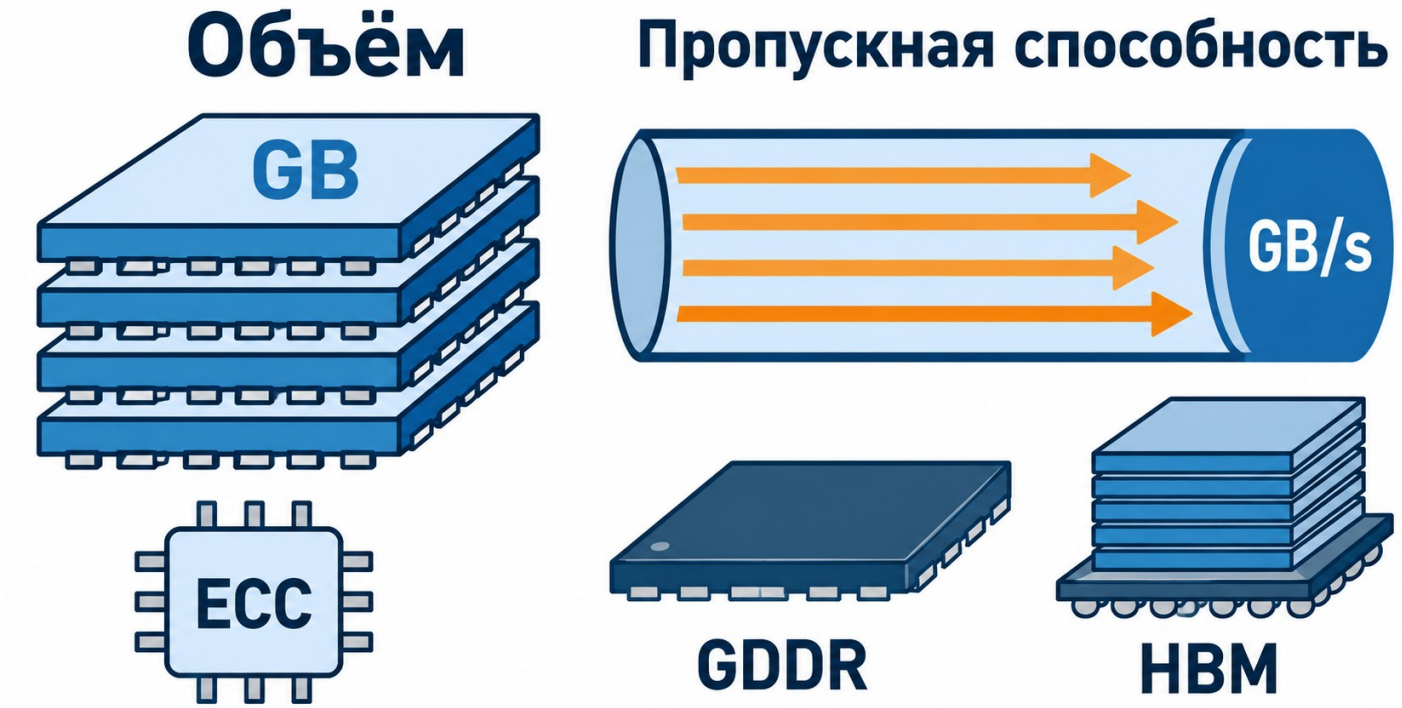
Иерархия памяти

Повторное использование близких данных сокращает обращения к VRAM.



NVIDIA

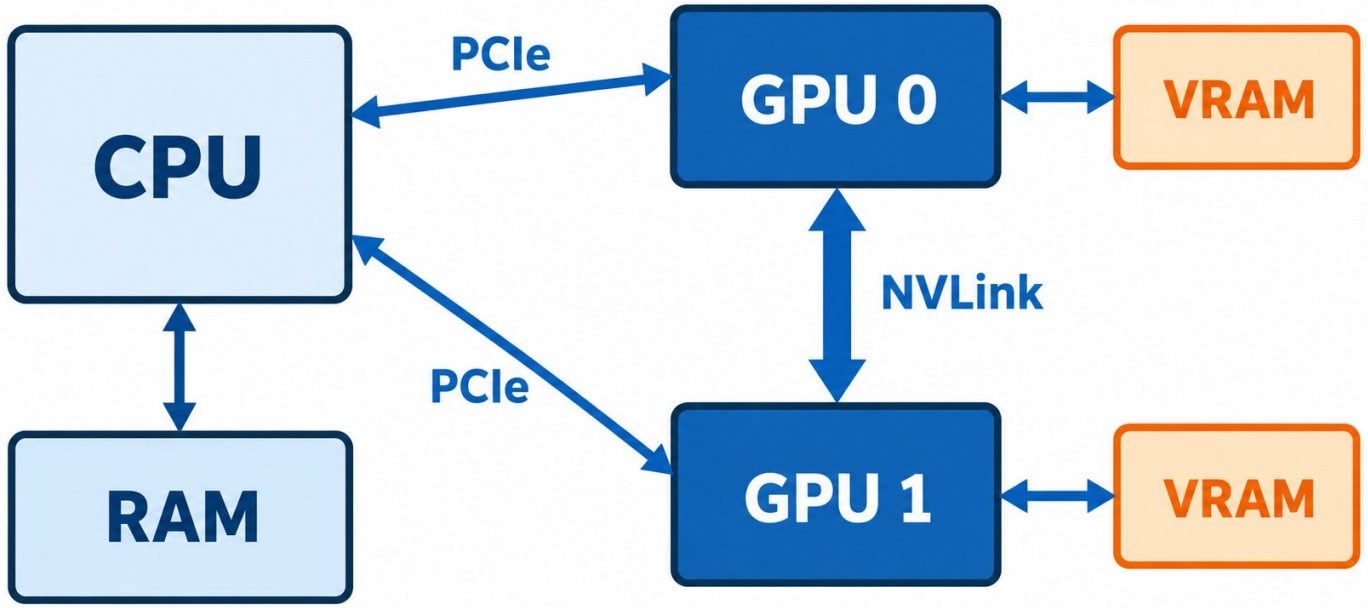
Видеопамять: объём и скорость



- GDDR — отдельные микросхемы памяти на плате
- HBM — стеки памяти с широким интерфейсом
- ECC — обнаружение и исправление ошибок памяти

NVIDIA

PCIe и NVLink



- PCIe: периферия и обмен GPU ↔ GPU
- NVLink: GPU ↔ GPU; C2C: CPU ↔ GPU/CPU
- NVSwitch: коммутатор NVLink для нескольких GPU

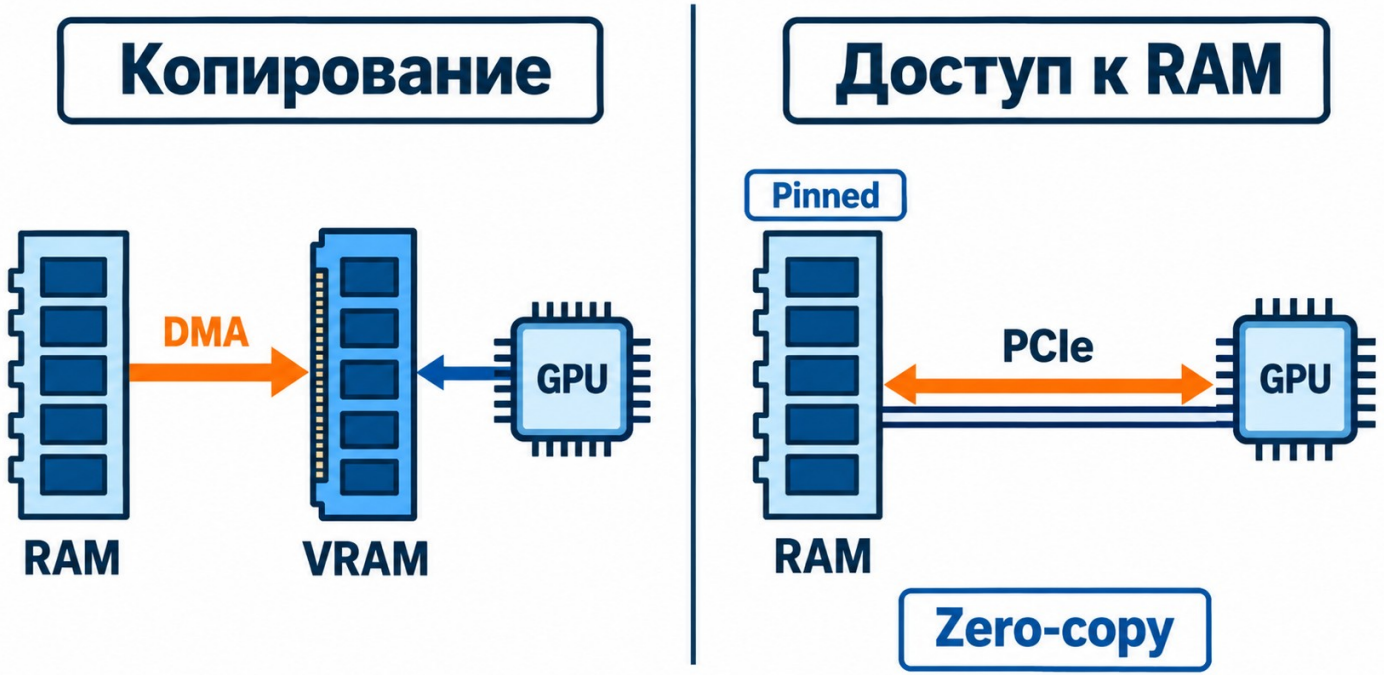
NVIDIA

Пропускная способность соединений

Интерфейс	→, GB/s	↔, GB/s	Суммирование
PCIe 3.0 x16	≈15,8	≈31,5	16 линий
PCIe 4.0 x16	≈31,5	≈63	16 линий
PCIe 5.0 x16	≈63	≈126	16 линий
NVLink 3 · A100 SXM	300	600	Все NVLink одной GPU
NVLink 4 · H100 SXM	450	900	Все NVLink одной GPU
NVLink 5 · Blackwell	900	1800	Все NVLink одной GPU

NVIDIA

DMA и zero-copy



- Копия в VRAM: многократное использование данных
- Цена: передача и место в VRAM
- Zero-copy: разовое чтение mapped RAM
- Цена: обращения через PCIe

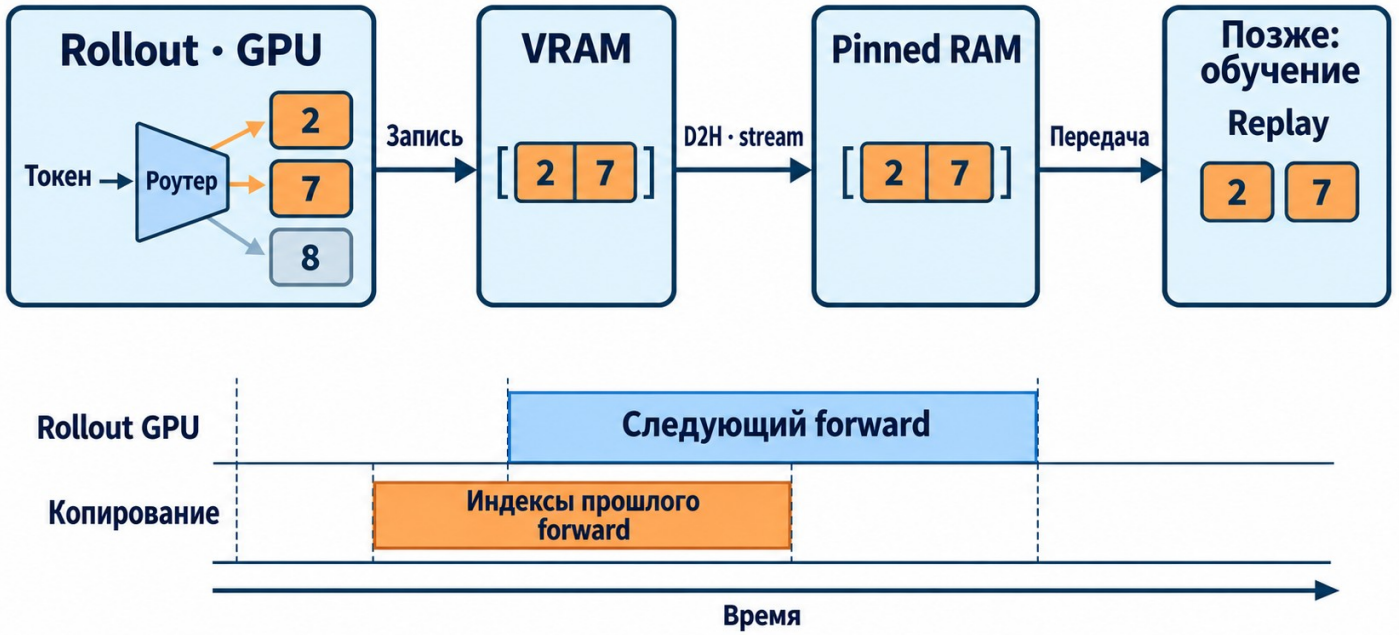
Асинхронность и CUDA streams



- CUDA stream — упорядоченная очередь операций GPU
- Используется для запусков kernels и копирования
- CPU продолжает работу, не ожидая завершения операций
- Разные streams позволяют перекрывать независимые операции

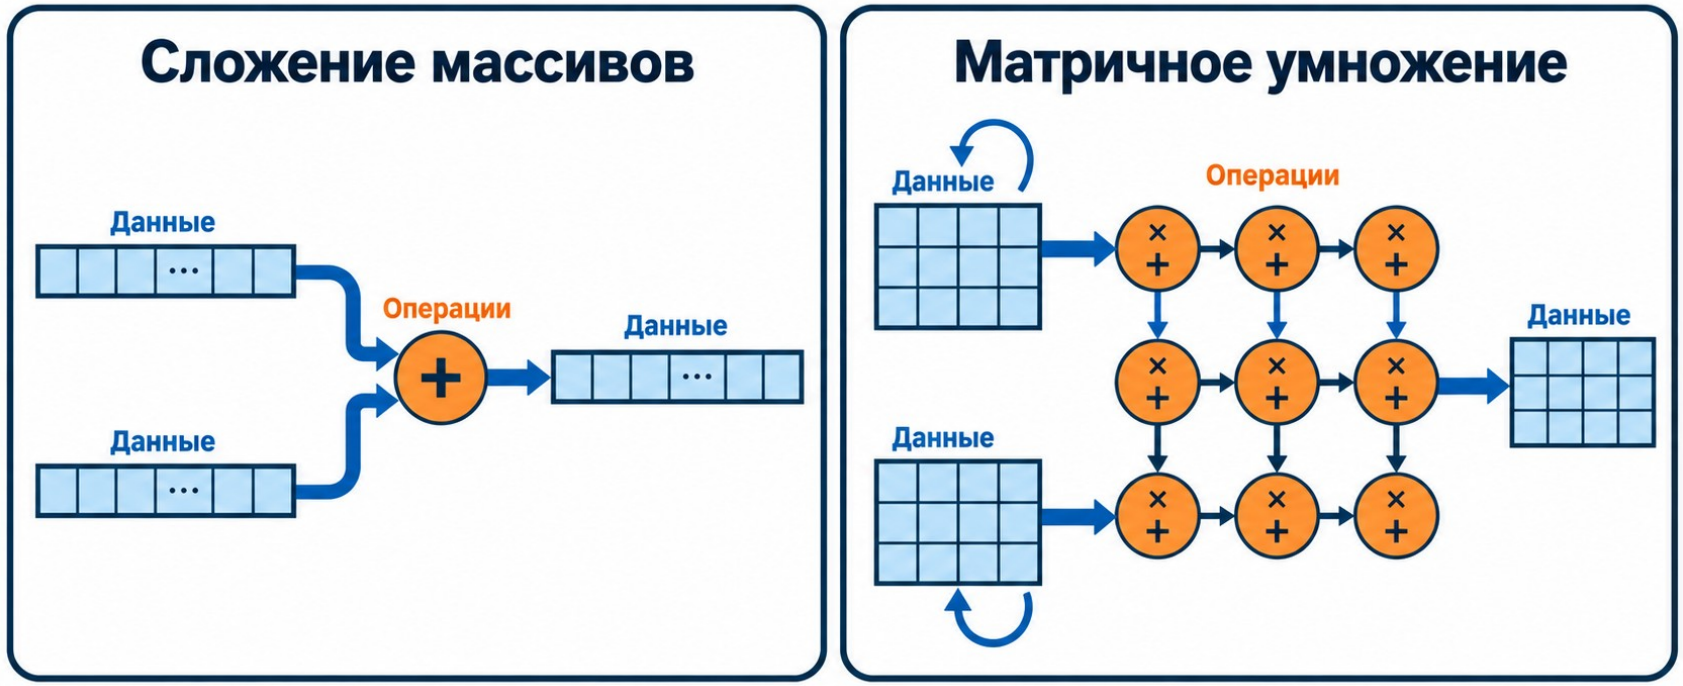
NVIDIA

Выгрузка маршрутов во время rollout

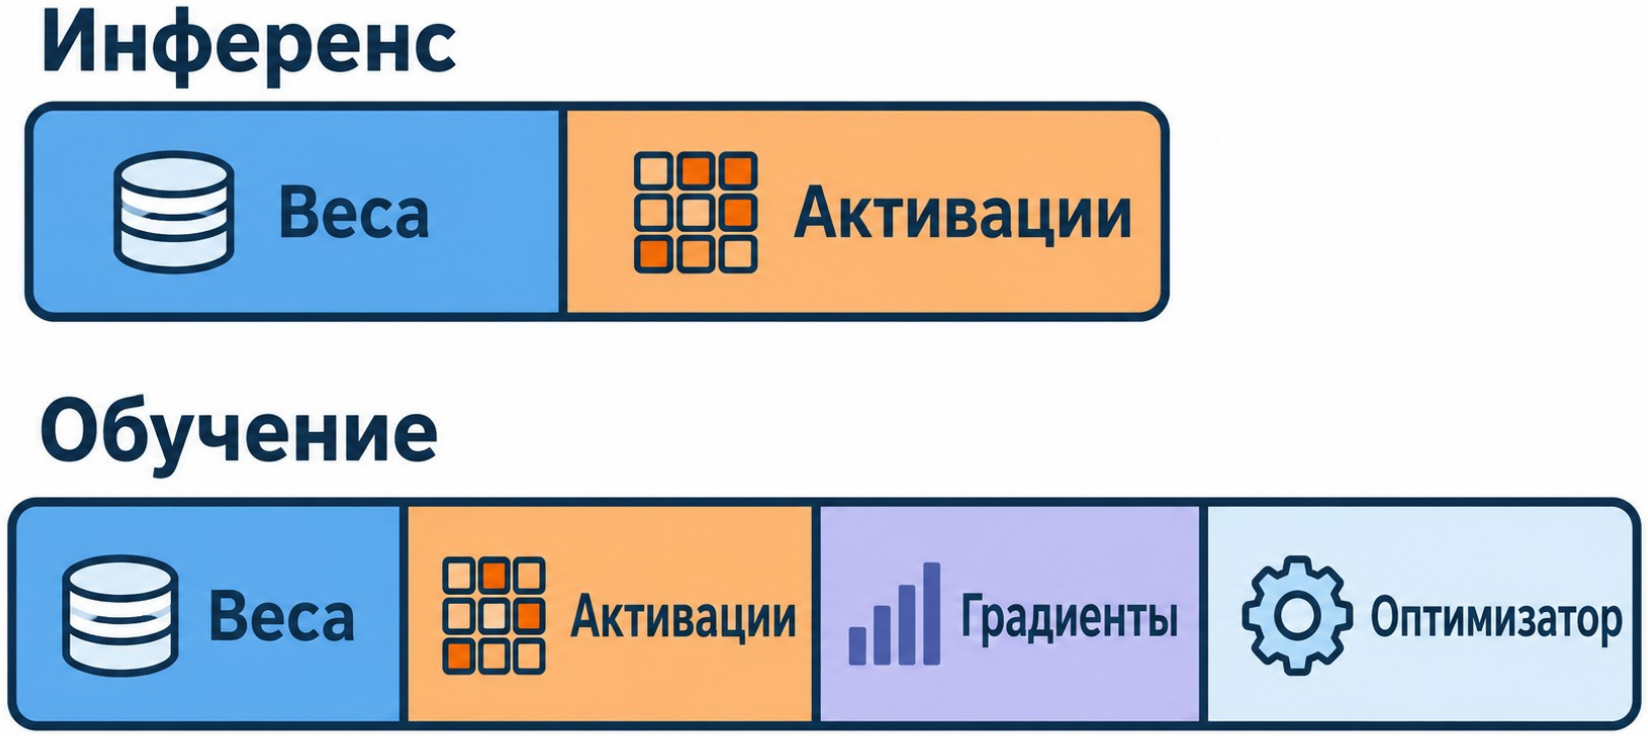


- DMA: VRAM → pinned RAM
- Отдельный stream: асинхронное копирование
- Выигрыш: перекрытие со следующим forward rollout

Вычисления или память

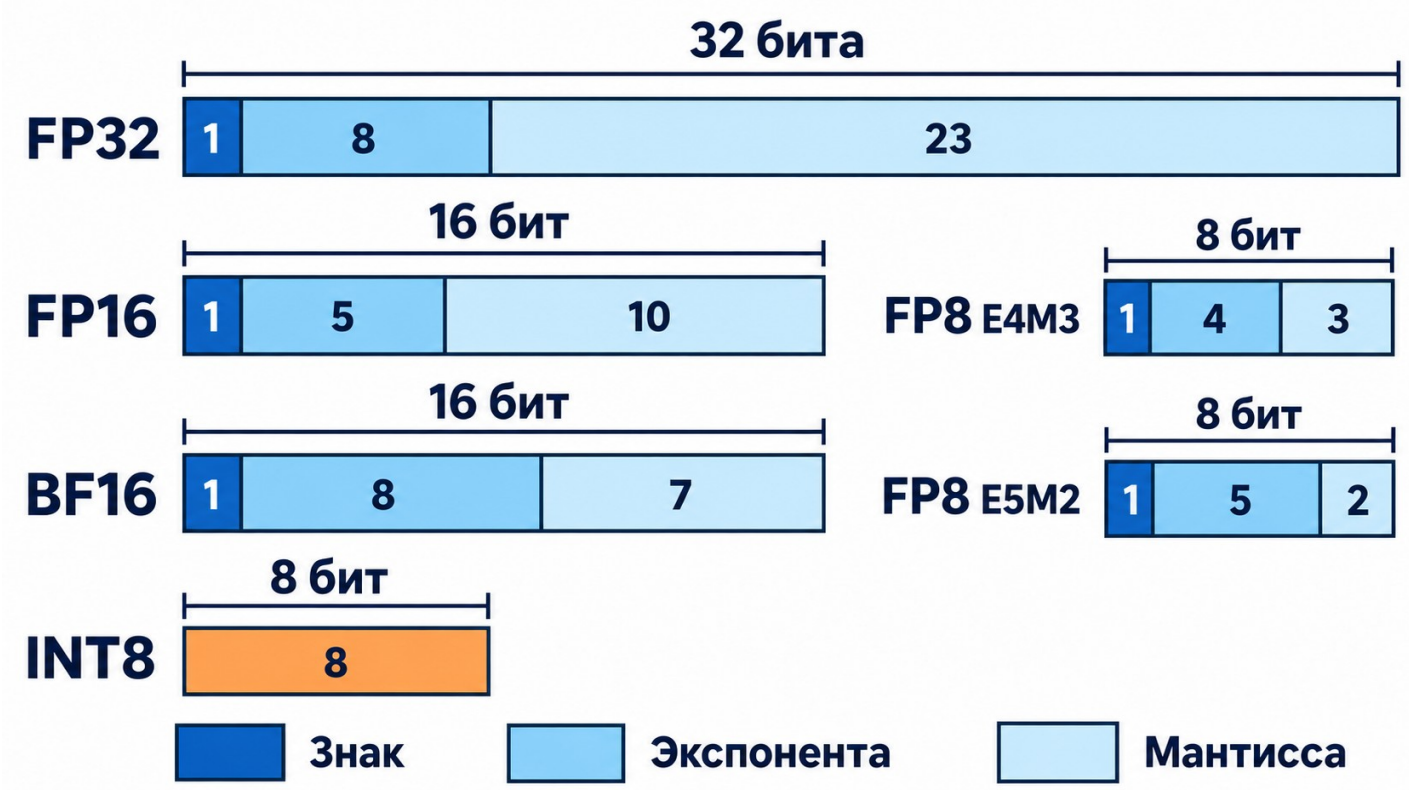


Куда расходуется VRAM



Условная схема

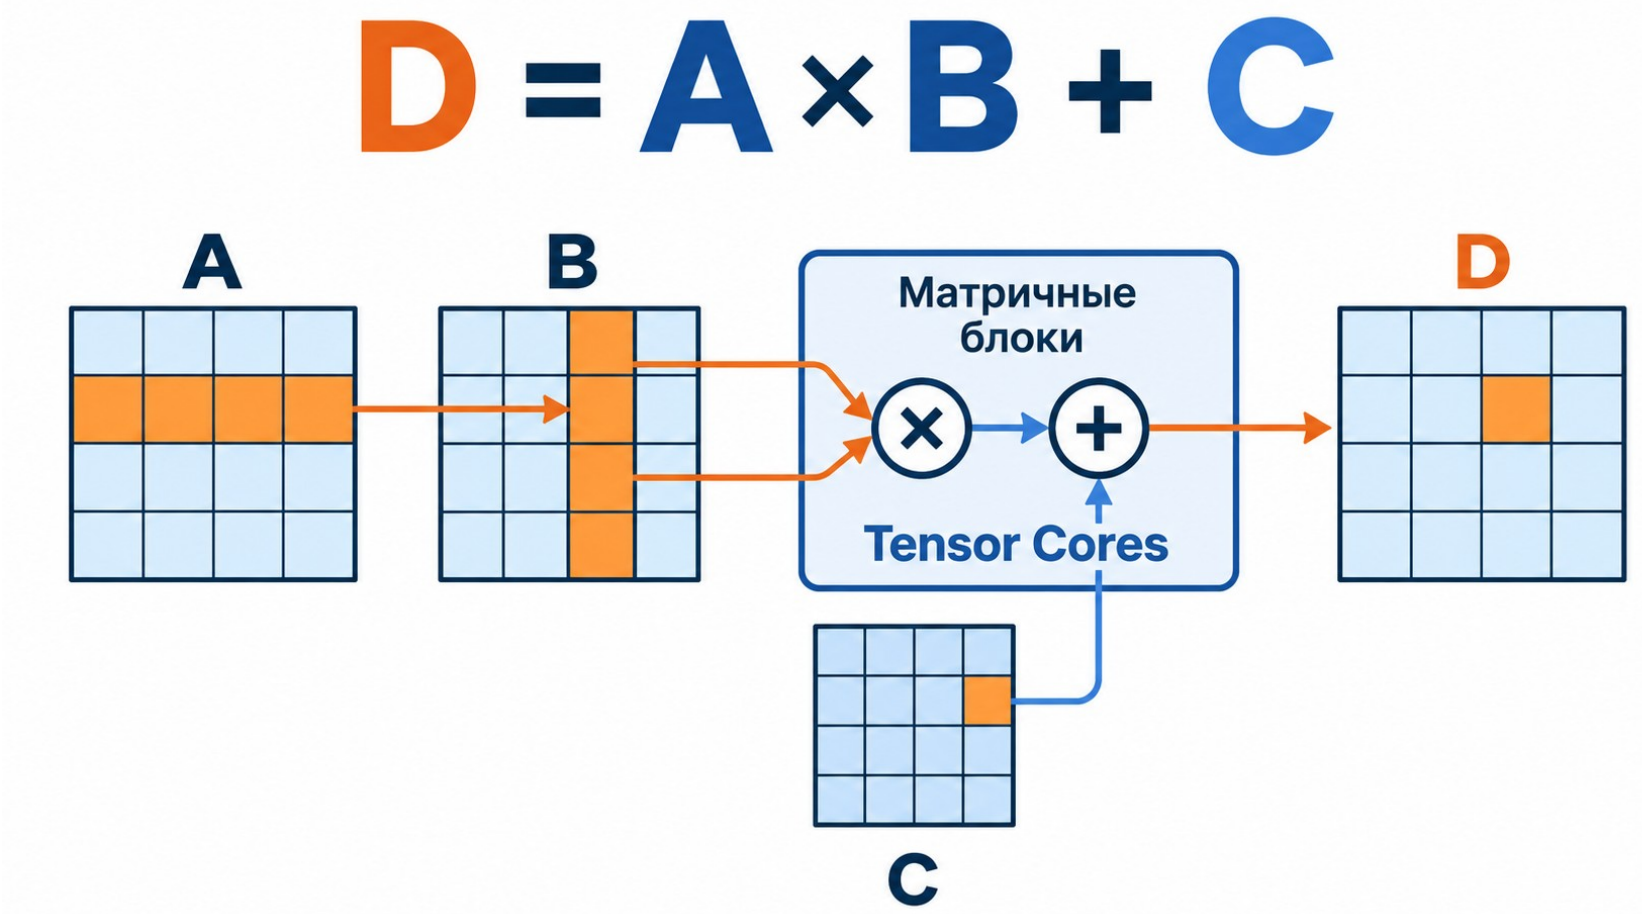
Числовые форматы



Пределы конечных значений

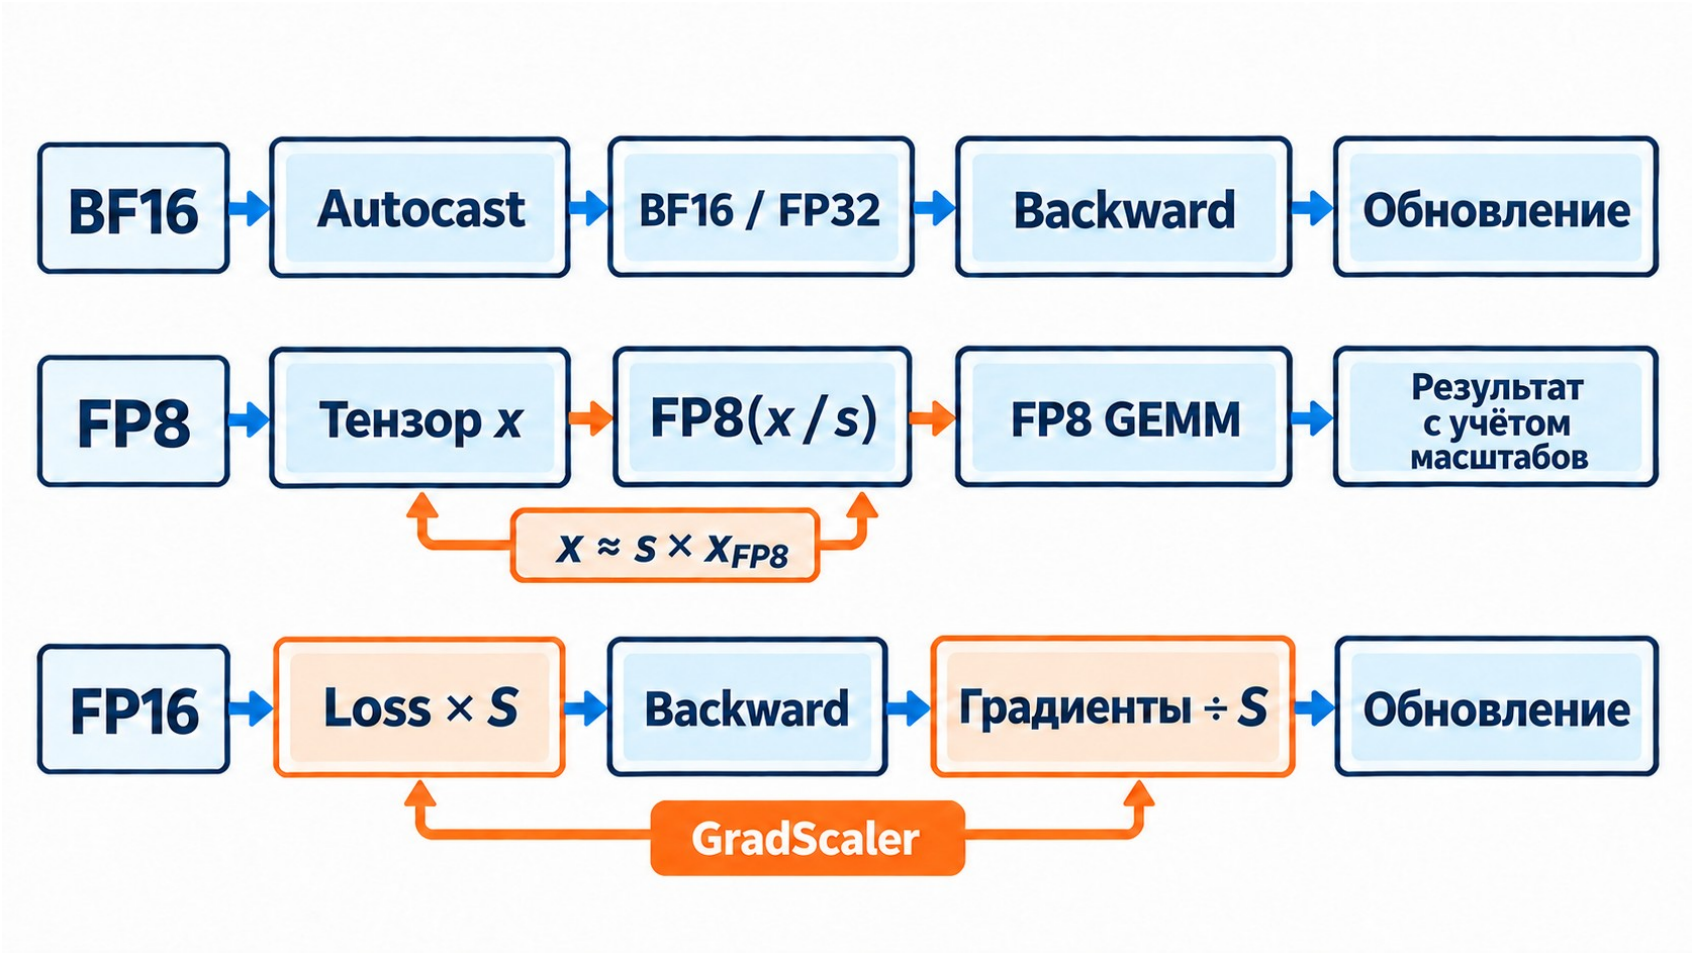
- FP32: ≈ ±3,40 × 10^{38}
- FP16: ±65 504
- BF16: ≈ ±3,39 × 10^{38}
- FP8 E4M3: ±448
- FP8 E5M2: ±57 344
- INT8: −128 … 127

Матричные операции на Tensor Cores



NVIDIA

Mixed precision и AMP



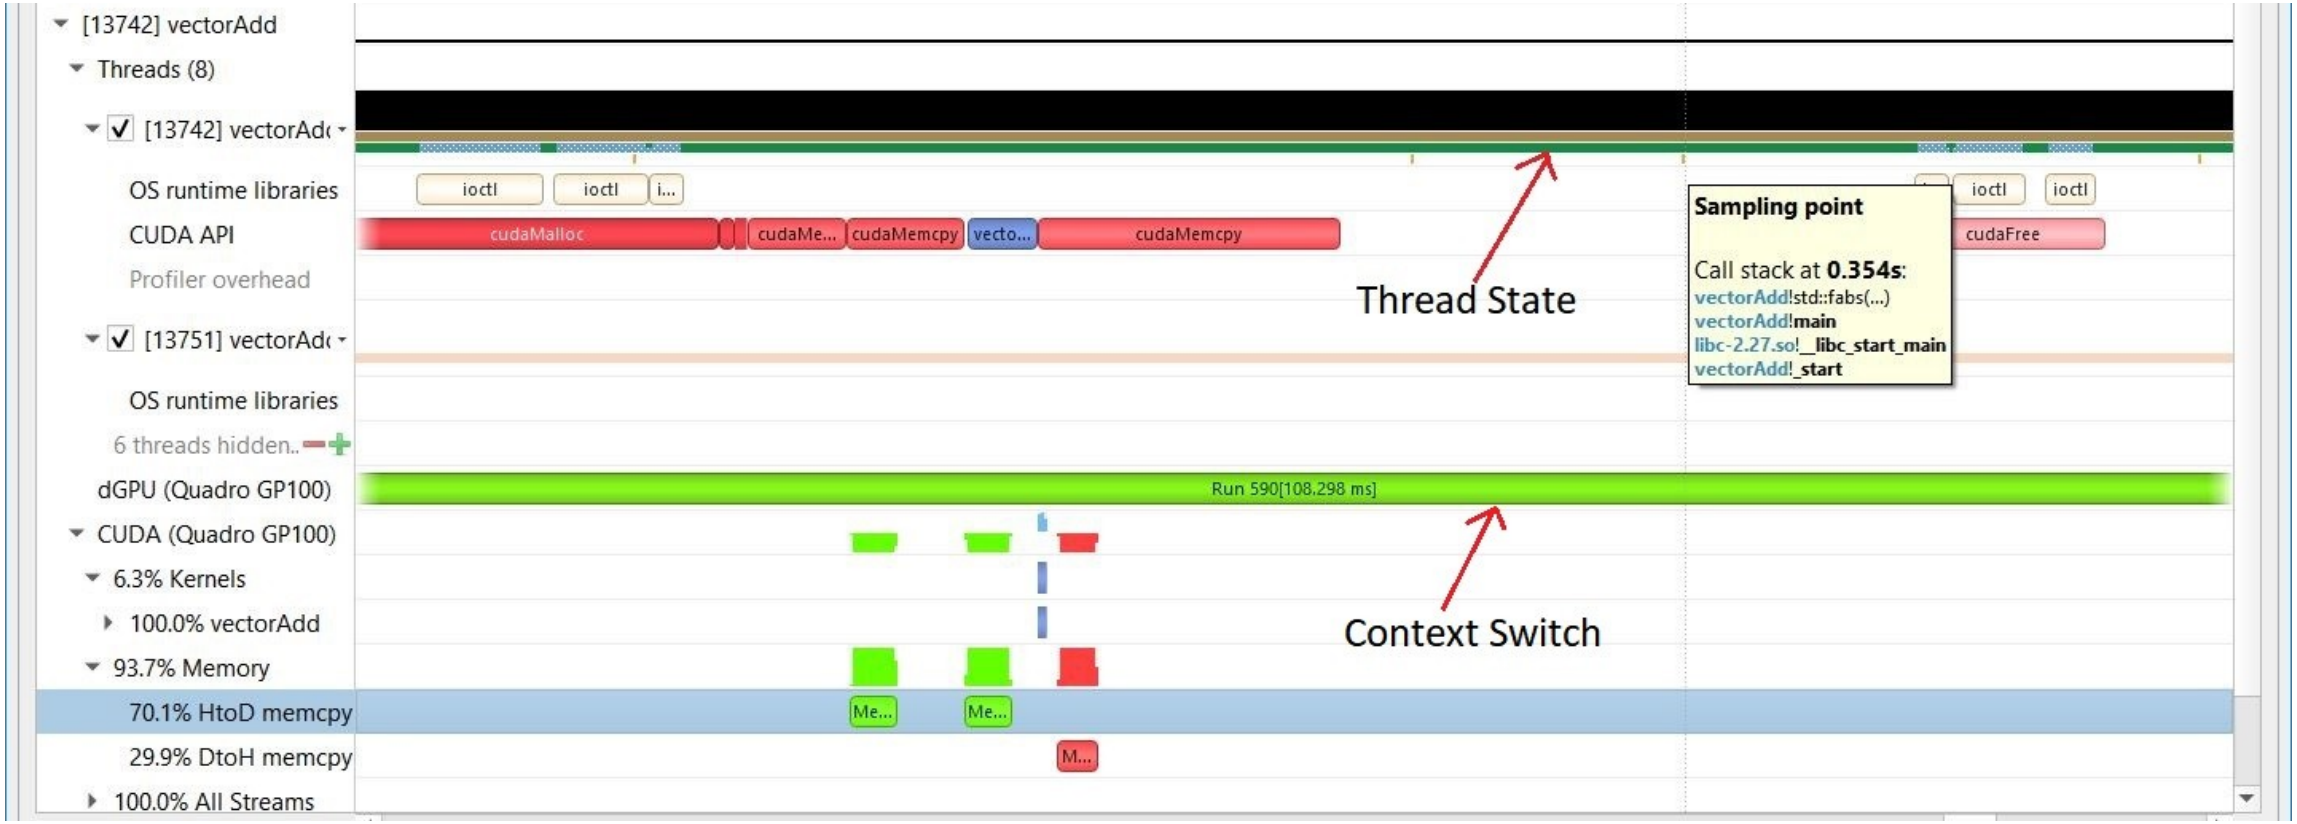
Как измерять время GPU

```
model.eval()
with torch.inference_mode():
    for _ in range(10): model(x)
    start = torch.cuda.Event(enable_timing=True)
    end = torch.cuda.Event(enable_timing=True)
    start.record()
    for _ in range(30): model(x)
    end.record()
    end.synchronize()
    print(start.elapsed_time(end) / 30)   # ms/iter
```

Читаем профиль выполнения

CPU / CUDA API

GPU: kernels и копирование



[NVIDIA, оригинальный профиль]

Что показывает nvidia-smi

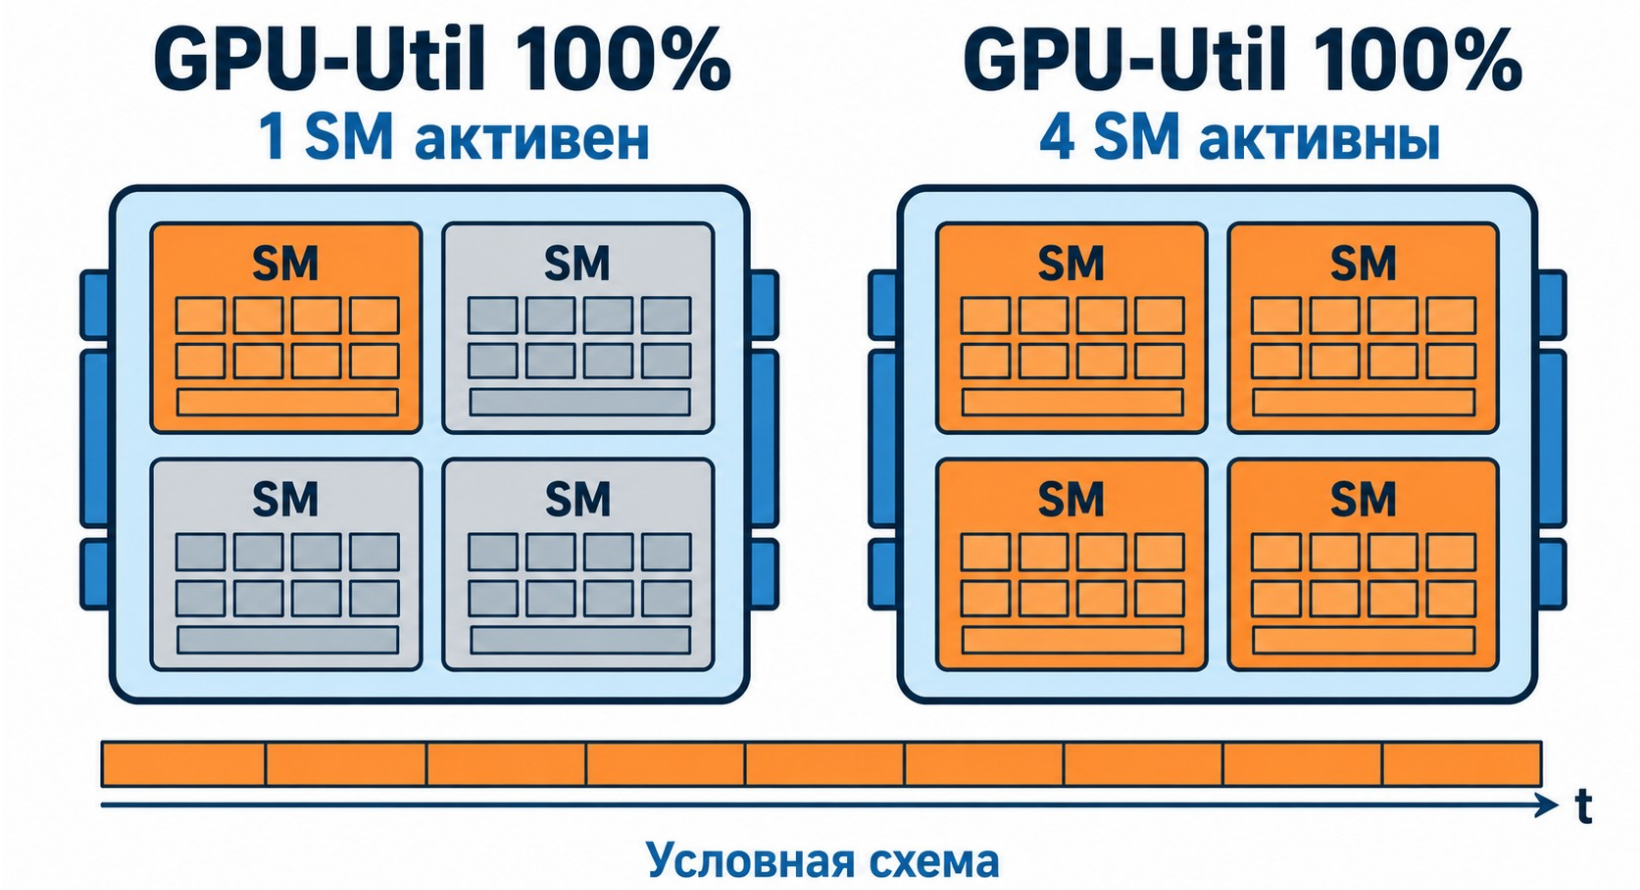
Memory-Usage — занятый объём. GPU-Util — время активности kernels.

```
# Сбор временного ряда
nvidia-smi \
  --query-gpu=utilization.gpu,utilization.memory,memory.used \
  --format=csv -l 1

# Фрагмент опубликованного примера NVIDIA
# Memory-Usage        GPU-Util
# 0MiB / 15109MiB          0%
```

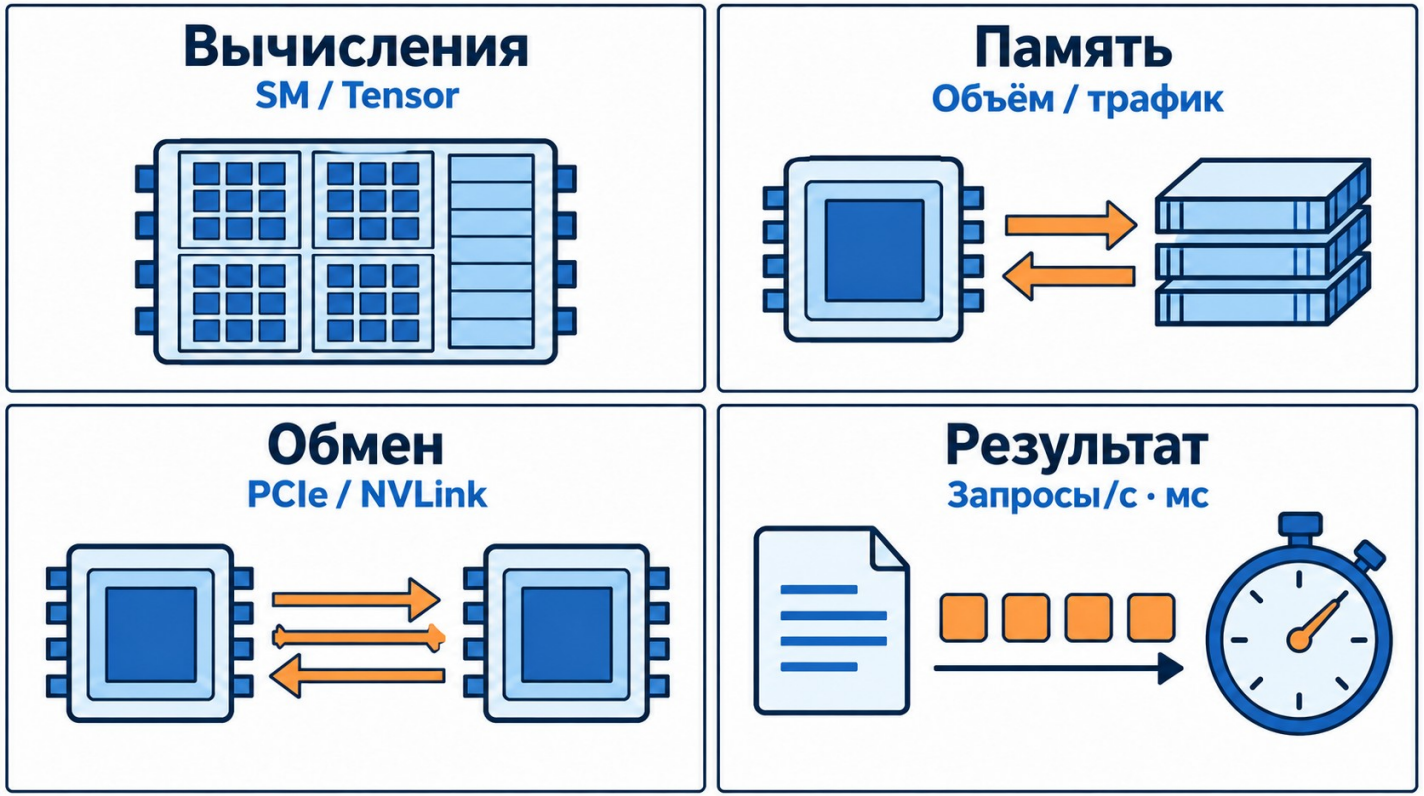
GPU-Util 100%: два разных случая

Окно одинаковое: SM activity 25% и 100%.



NVIDIA

Какие метрики нужны вместе

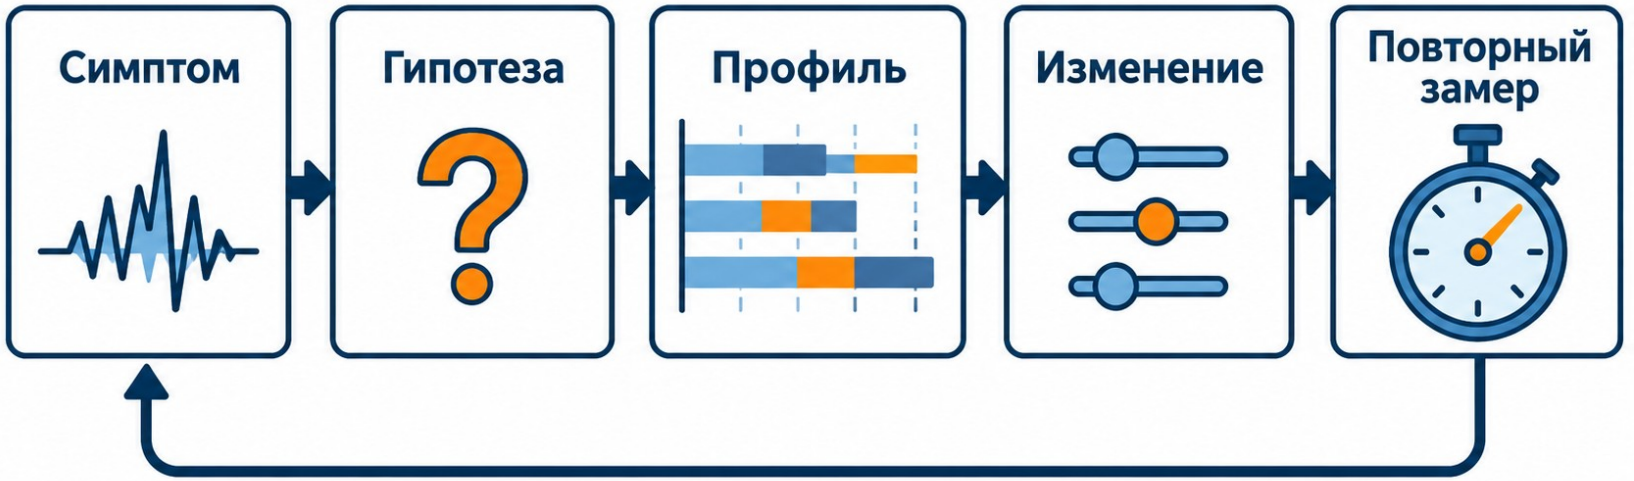


- SM activity, occupancy, Tensor activity
- VRAM (MiB), DRAM activity
- Трафик VRAM, PCIe, NVLink (GB/s)
- Запросы/с, задержка (мс)
- Частоты, мощность, температура, ошибки ECC

NVIDIA

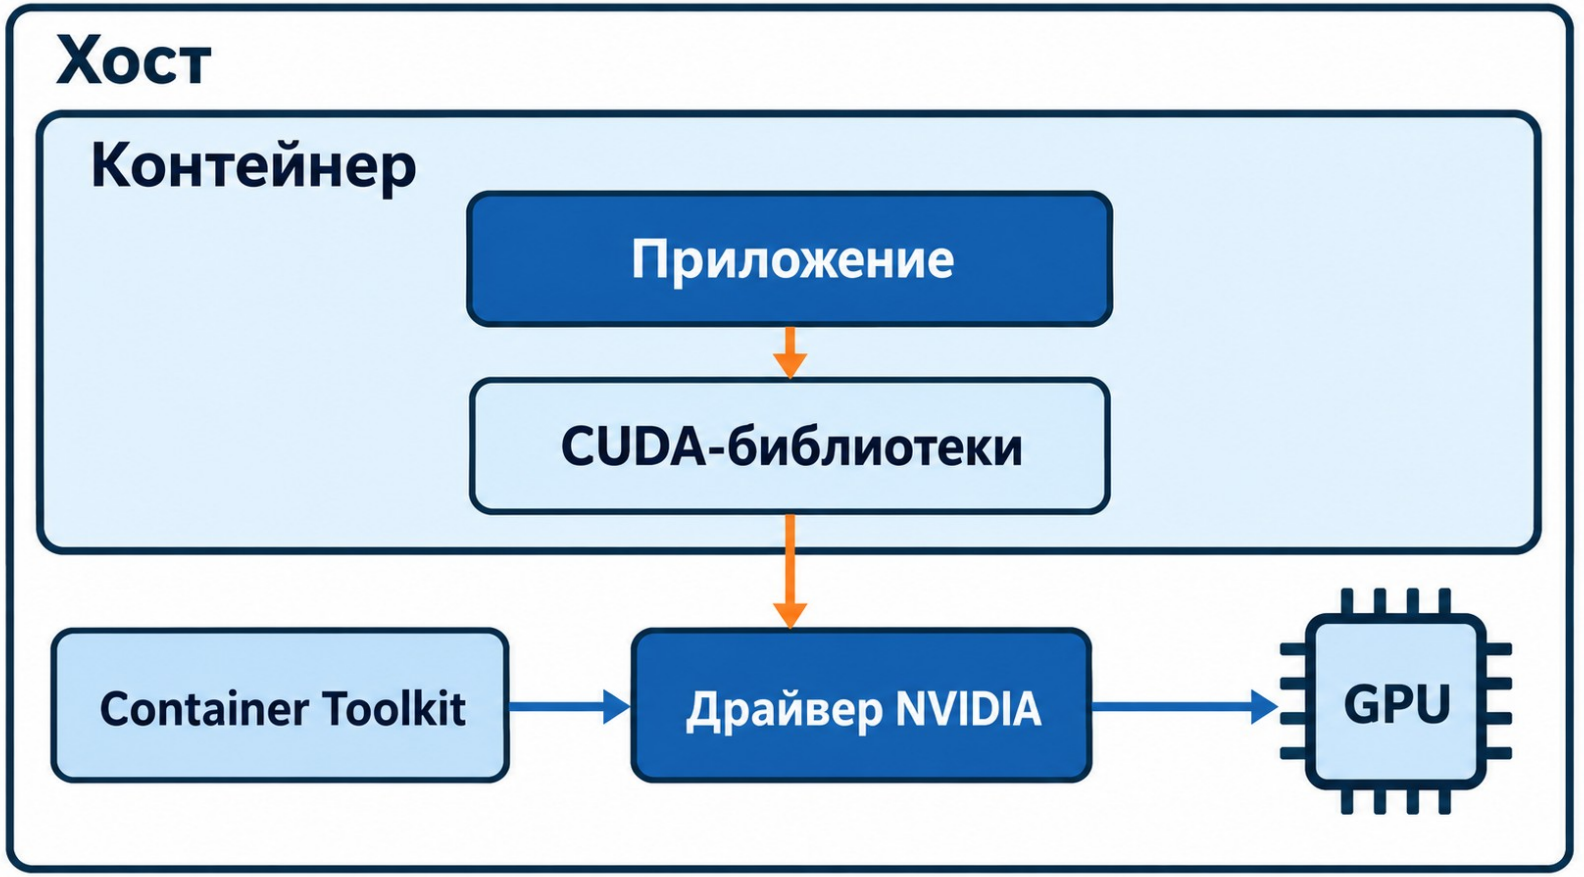
От мониторинга к проверке причины

Гипотеза: мало параллельной работы. Проверка: размер запуска.



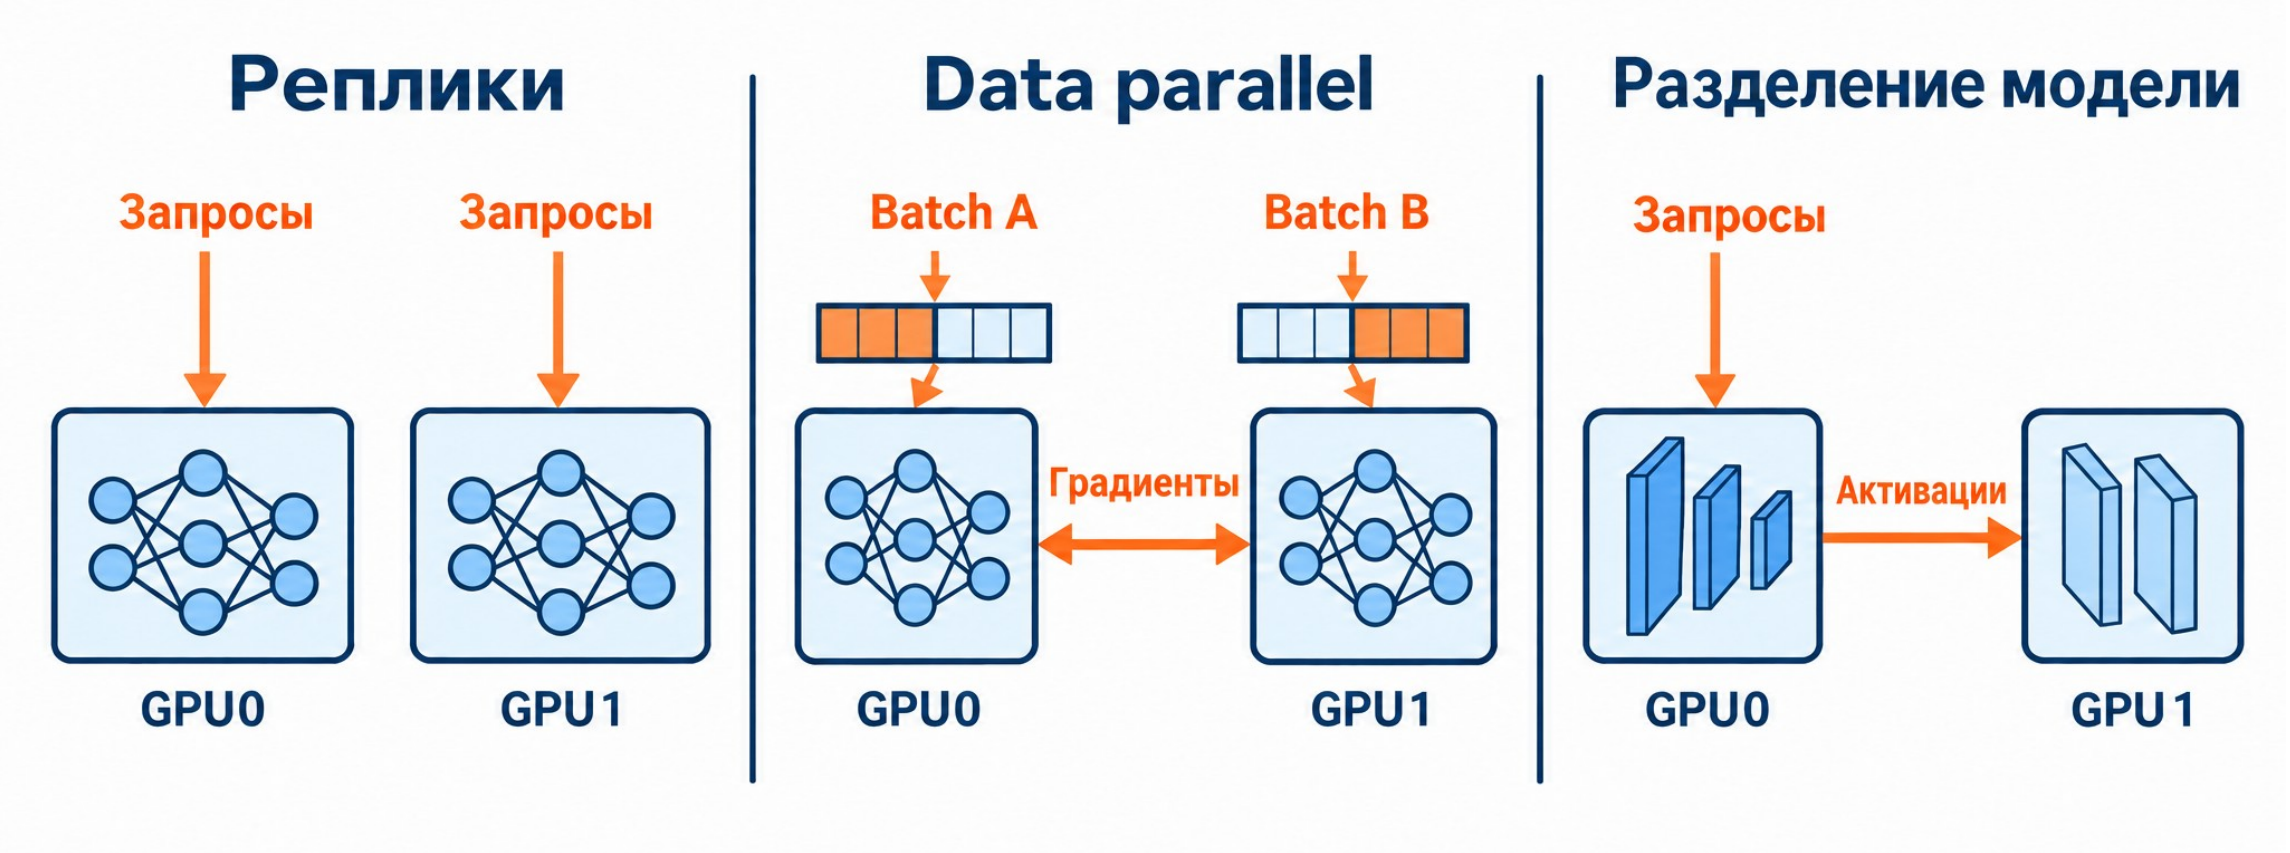
GPU внутри Docker

Драйвер остаётся на хосте; контейнеру предоставляется доступ к GPU.

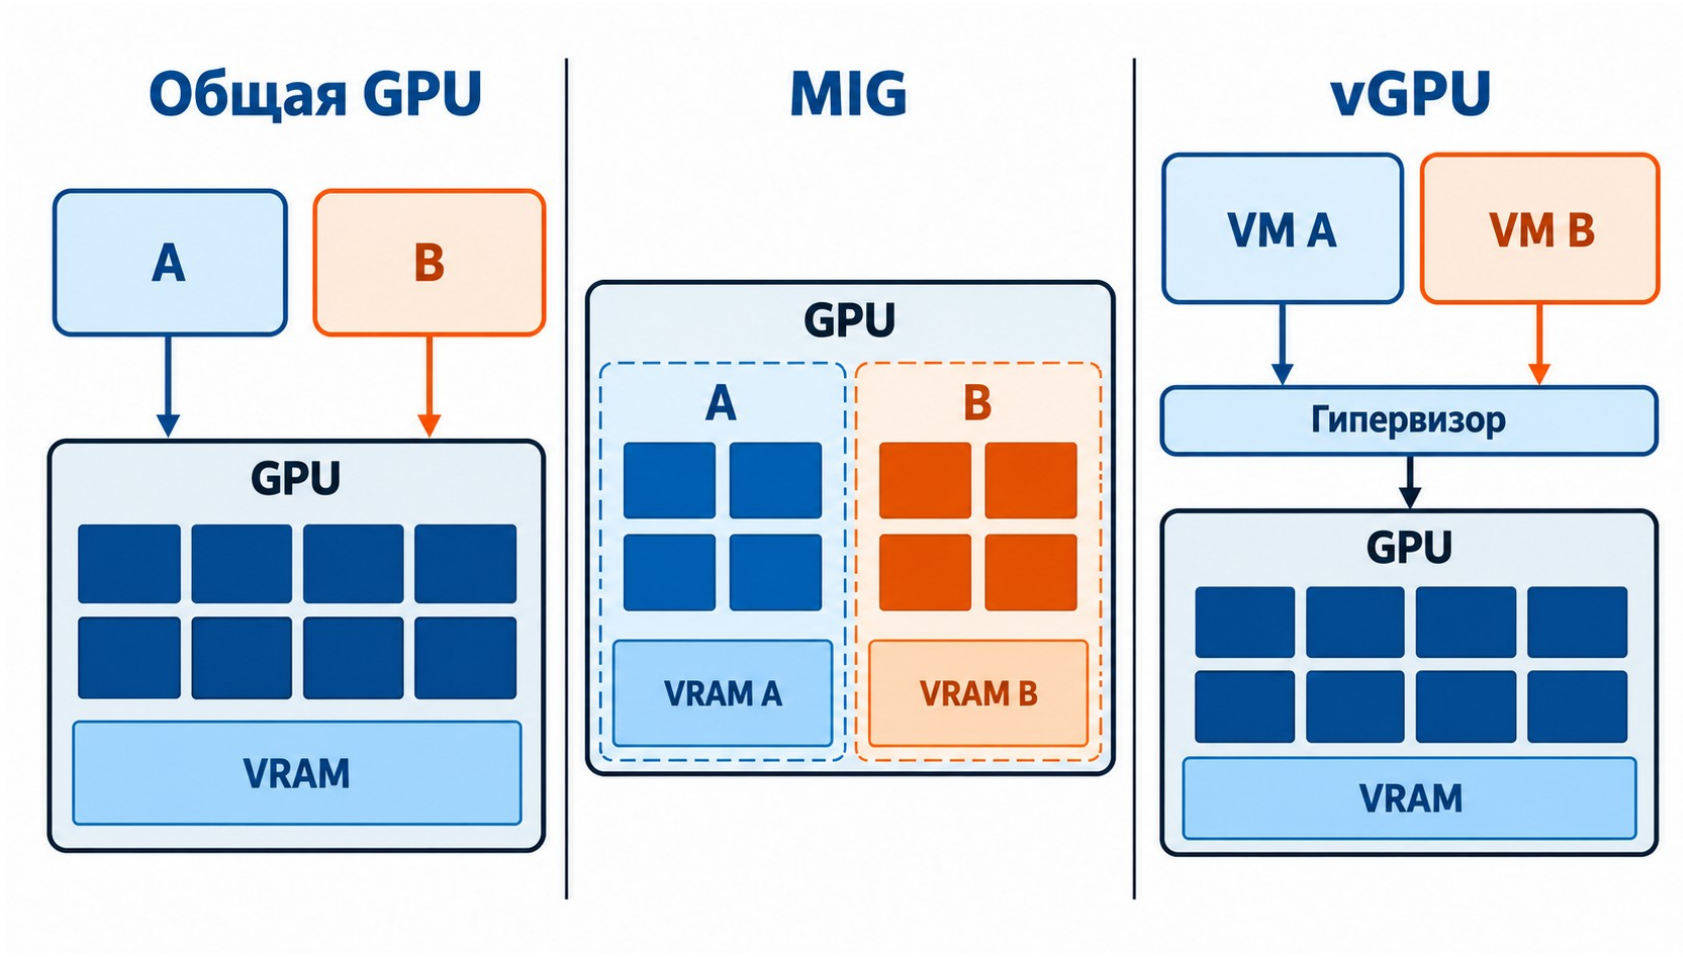


NVIDIA

Несколько GPU: разные задачи



MIG и vGPU



NVIDIA

Итоги

- GPU выполняет массовую параллельную работу
- Передачи и память ограничивают скорость
- Точность меняет вычисления и расход памяти
- GPU-Util дополняем профилем и скоростью